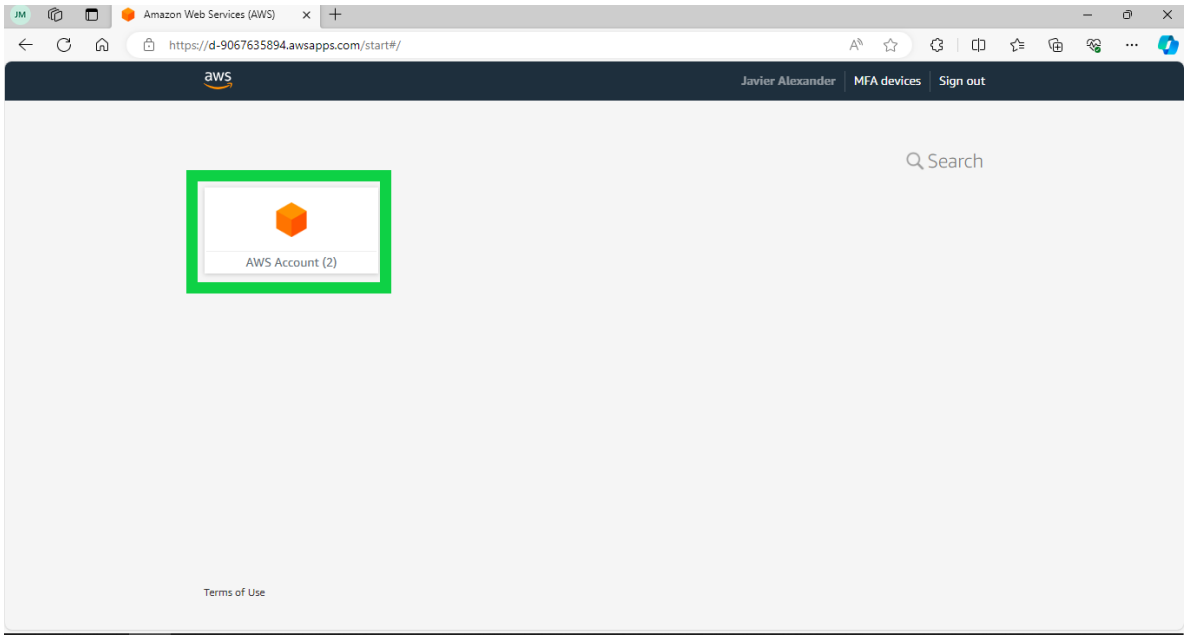
Manual de configuración para construcción de recetas en AWS GlueDataBrew y servicio S3

El siguiente manual presenta la manera de ingresar a la herramienta de AWS GlueDataBrew, para la construcción de recetas con diferentes tipos de archivos de entrada.

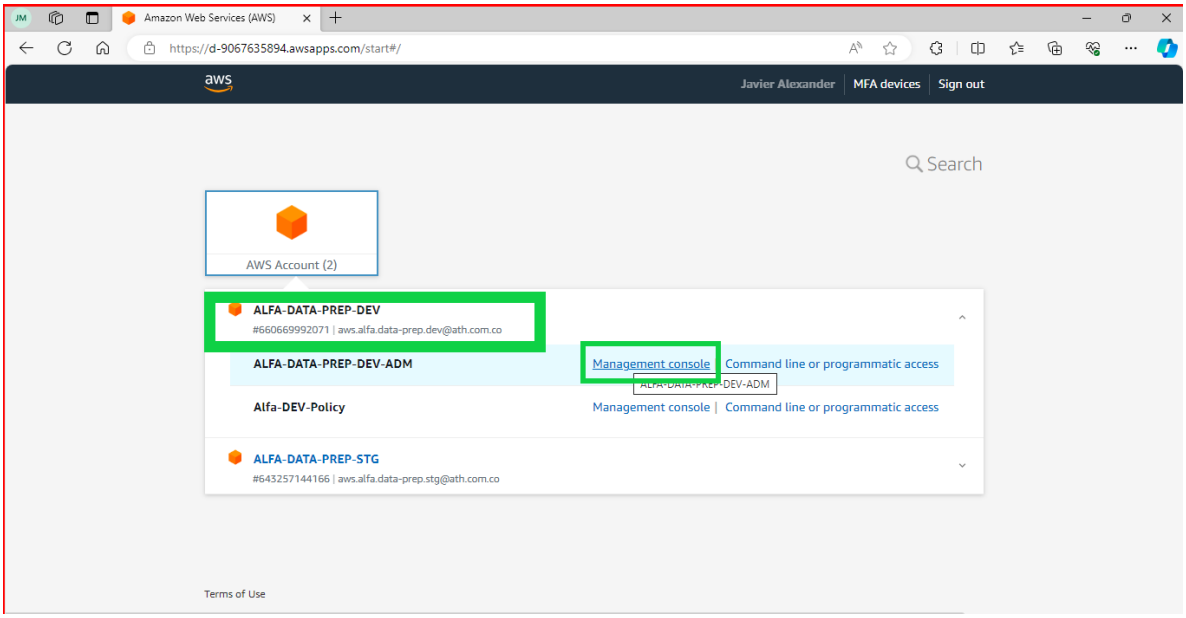
A continuación, se describe el paso a paso:

- Ingresar al link https://ssoath-lz.awsapps.com/start/#/de AWS GlueDataBrew, e ingresar con las credenciales asignadas.

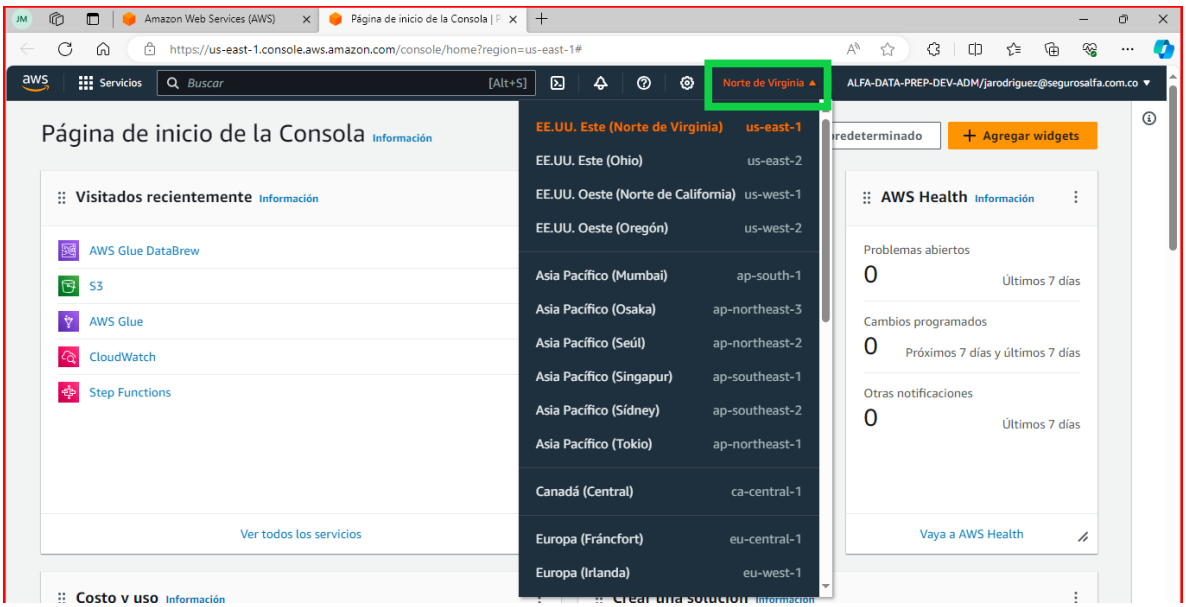
  Aparecerá lo siguiente, damos clic en



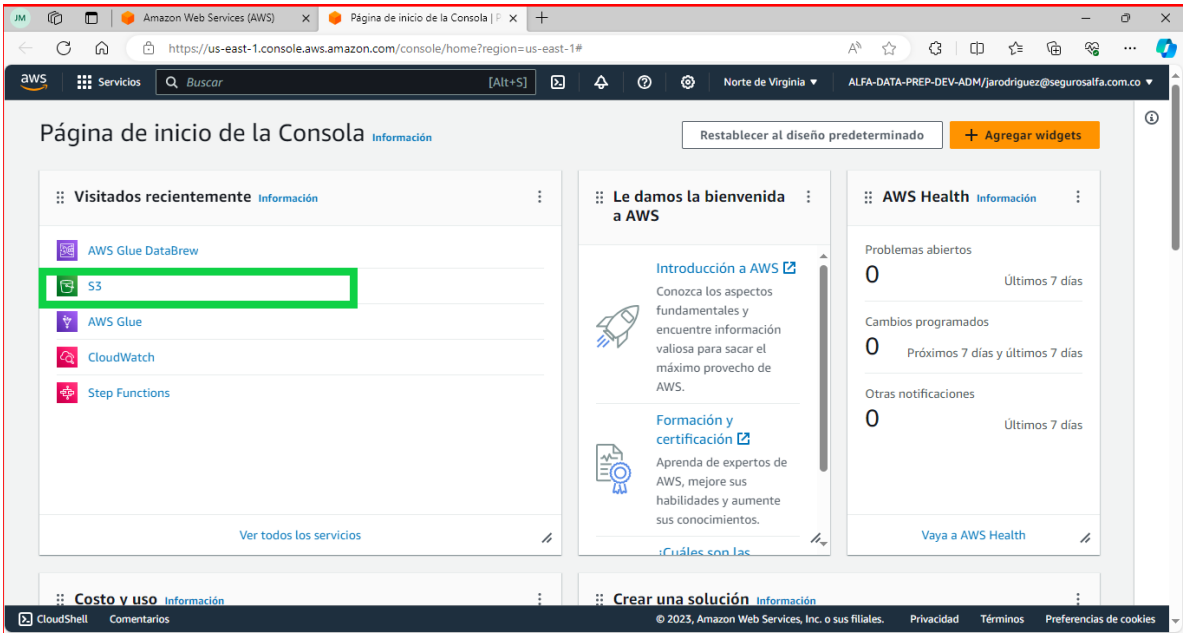
- Se debe ingresar al ambiente desarrollo ALFA-DATA-PREP-DEV y luego a la opción management console.



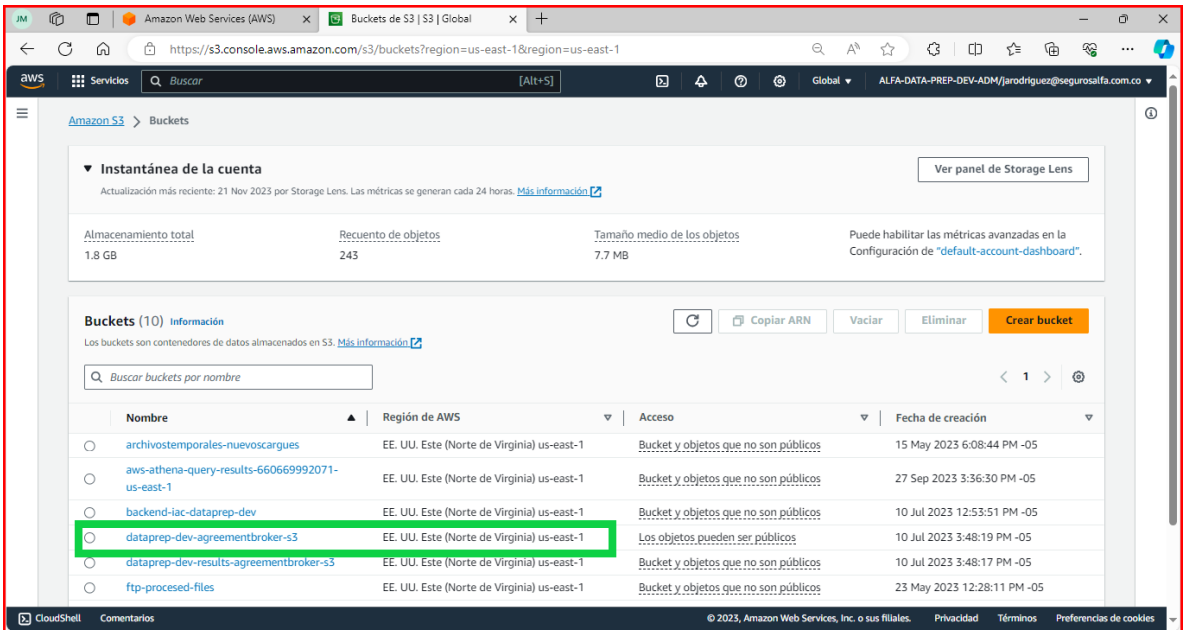
- Aparecerá la pagina de inicio de la consola.
  Se debe seleccionar la región por defecto **Norte de Virginia.**



- Se debe seleccionar el servicio **S3,** para la configuración inicial de archivos de entrada.

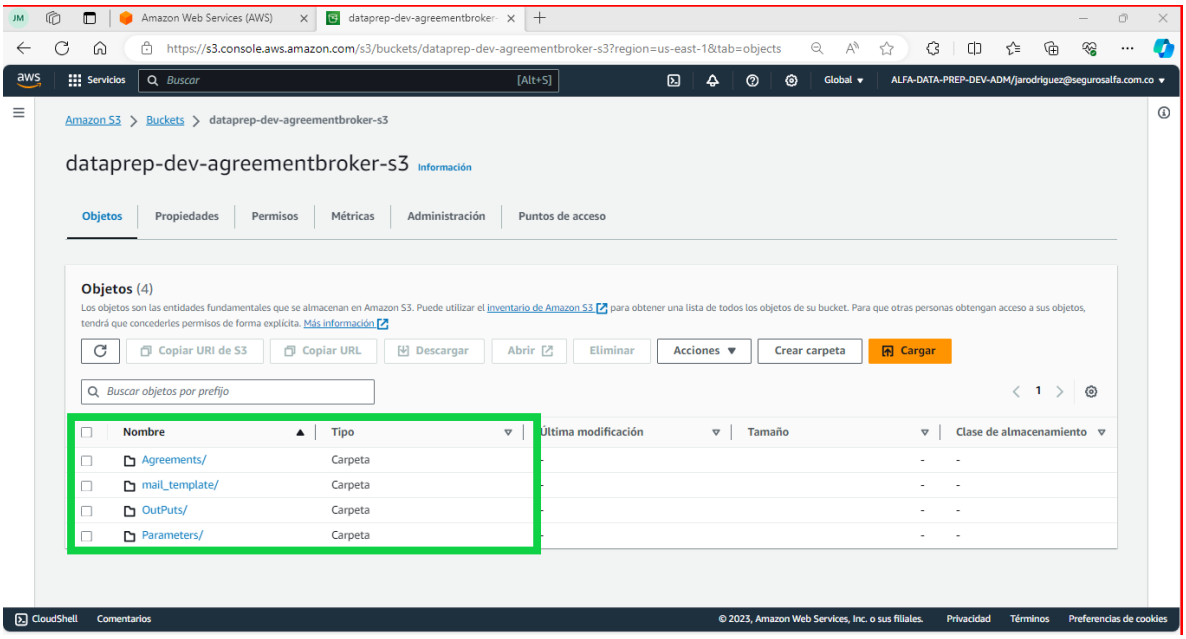


- A continuación aparece el panel de Buckets(almacenamiento de archivos), damos clic en la opción de [dataprep-dev-agreementbroker-s3]

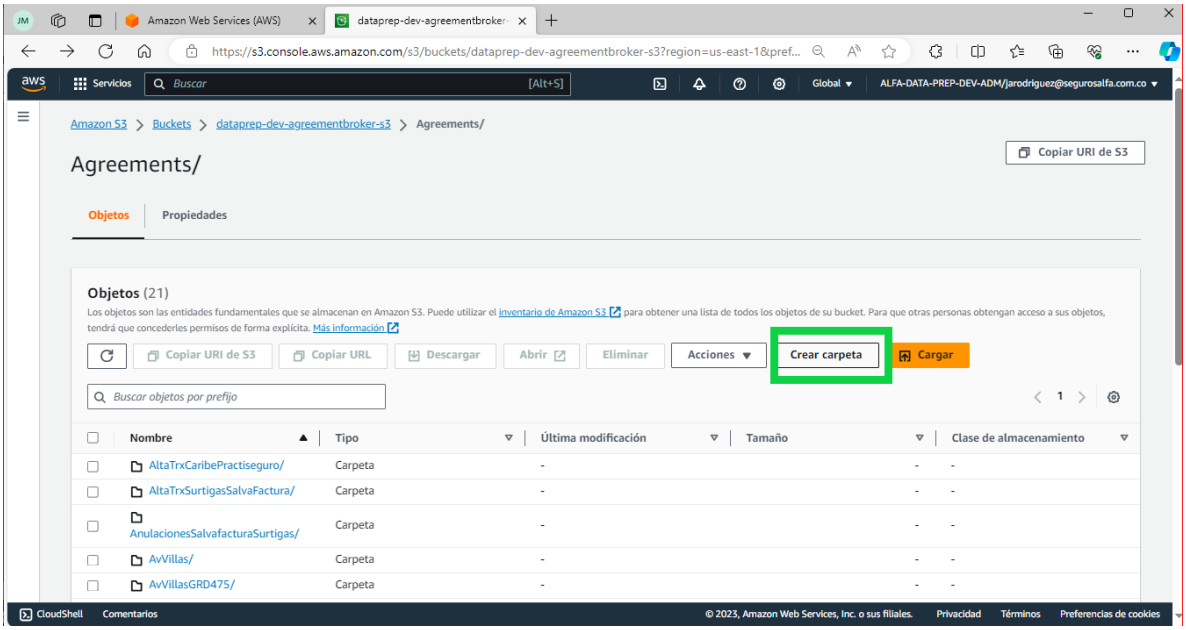


- Nos aparecerá la siguiente pantalla donde se visualiza 4 carpetas:

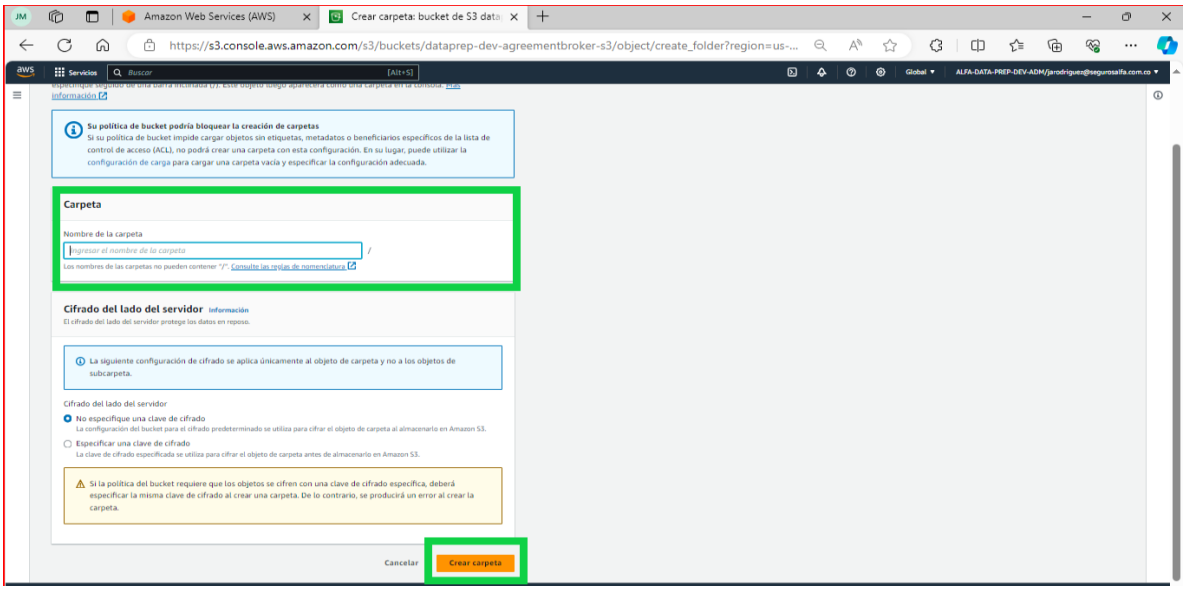
- Agreements/ En esta carpeta se crean subcarpetas por cada Cartera y es donde se aloja los archivos de entrada para la construcción de la receta.
- mail_template/ En esta carpeta no es necesario para el proceso de recetas, sin embargo, aloja configuraciones del servicio de E-mail.
- OutPuts/ En esta carpeta es donde se configuran los archivos de salida después de procesada la receta, de igual manera aloja información por carpeta para cada cartera.
- Parameters/ En esta carpeta se guardan aquellos archivos donde deben cruzar información en la receta con el archivo de entrada, ejemplo DIvipola, tarifas de pólizas.



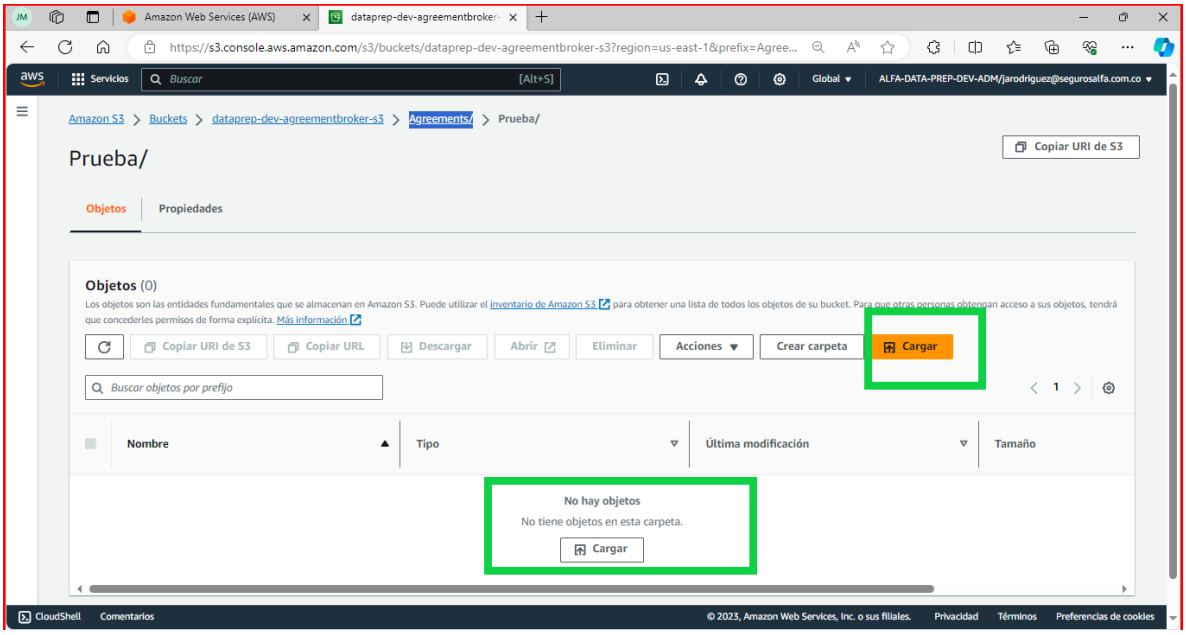
- Para la creación de carpetas y cargue de archivos se realiza lo siguiente.
  Se selecciona cualquier ubicación y se da clic en crear carpeta.



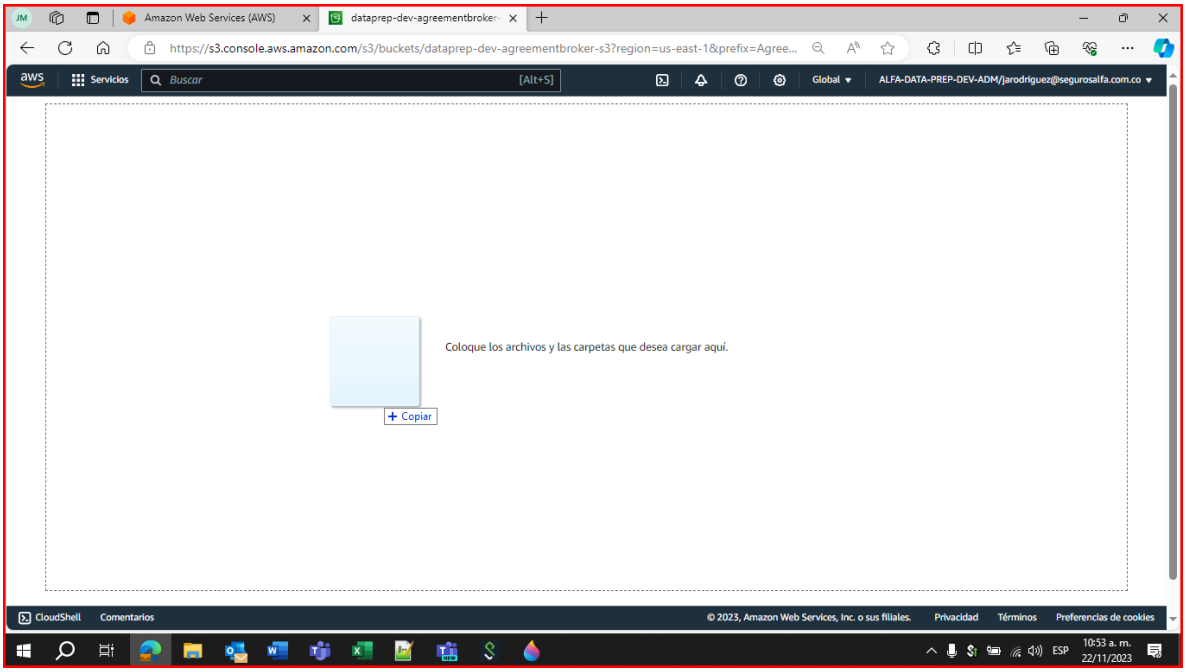
Dar el nombre de la carpeta de acuerdo a la cartera o proceso y dar clic en botón crear carpeta.



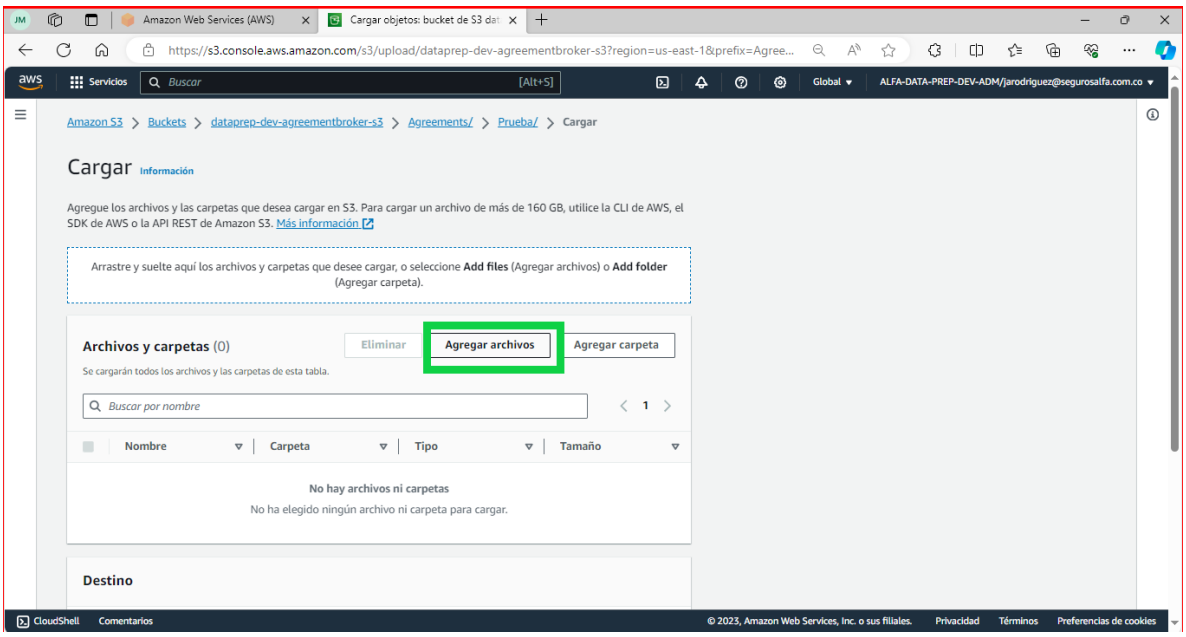
Para cargar el archivo de entrada en este caso se utiliza la carpeta de Agreements/ damos en opción Cargar para seleccionar el archivo local o simplemente podemos arrastrar el archivo con clic sostenido y soltando en la parte inferior en cargar desde nuestra maquina local el archivo que deseamos cargar.



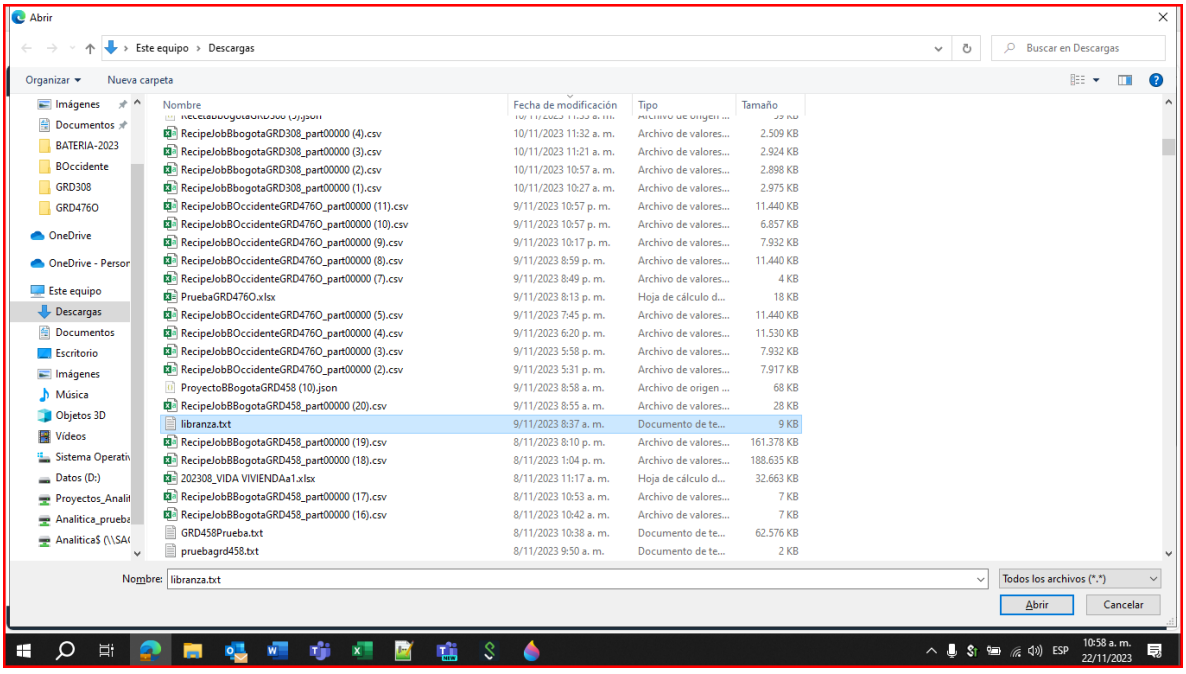
Arrastrando el archivo.



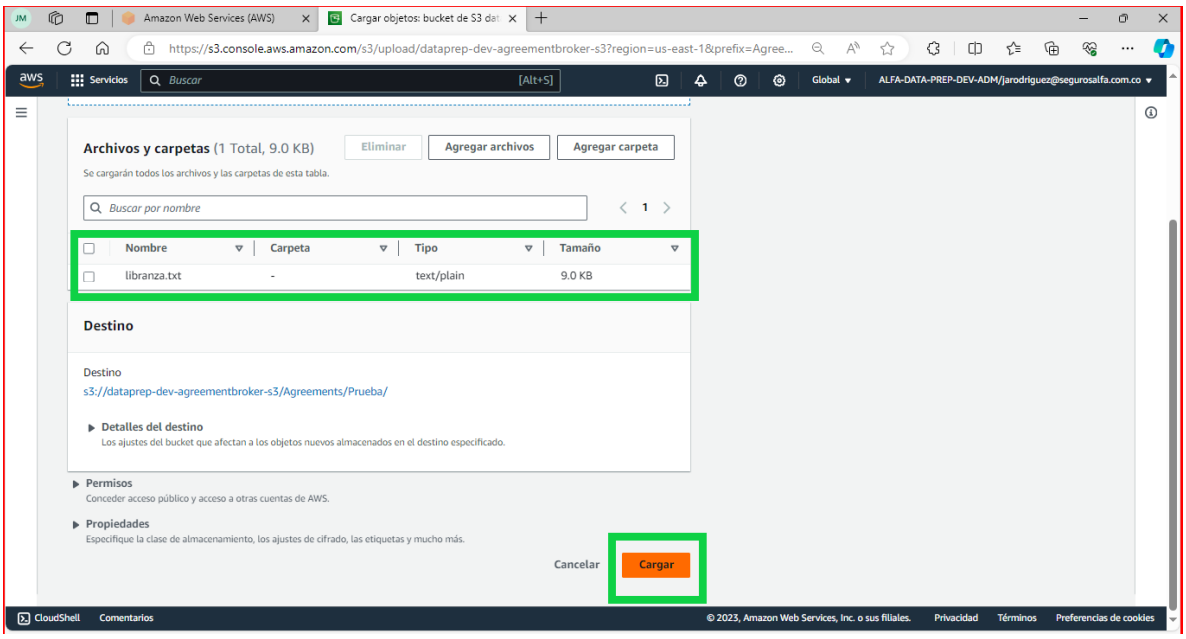
Cargando el archivo desde el botón cargar. Clic en agregar archivos.



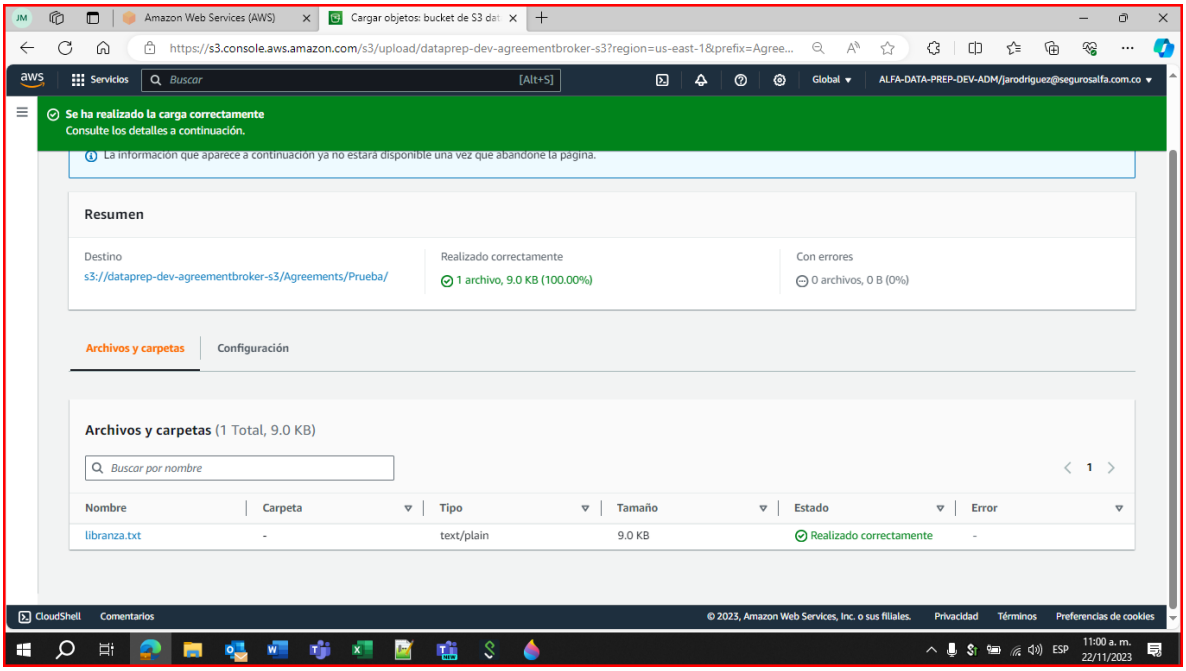
Seleccionar el archivo y dar clic en abrir.



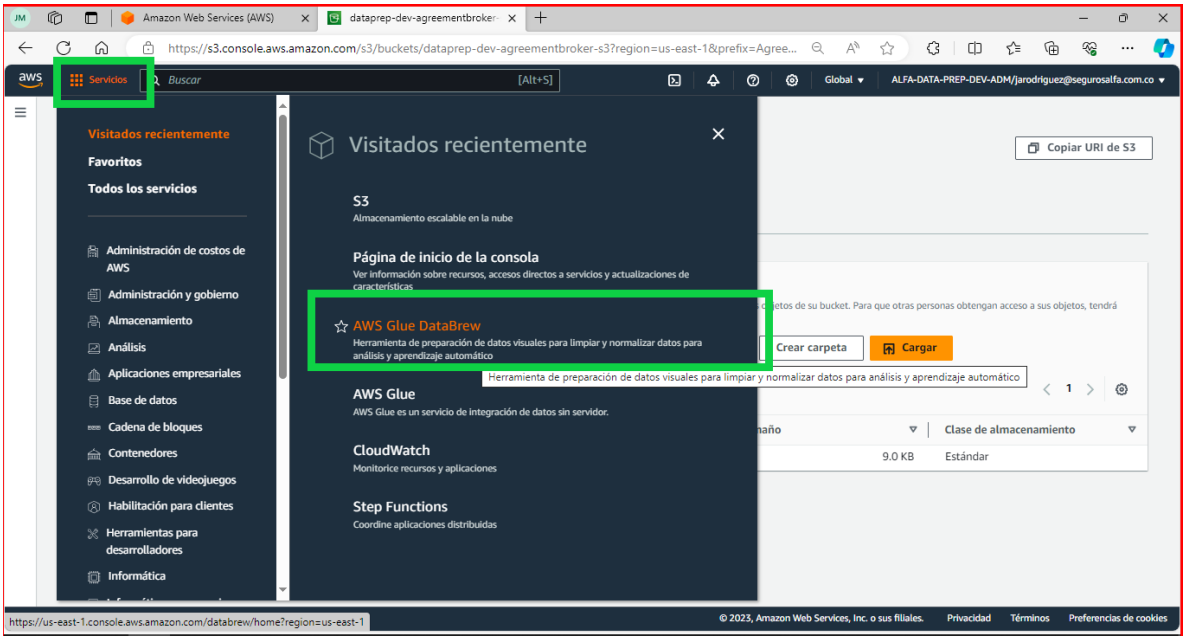
Se sube el archivo y luego dar clic en cargar.



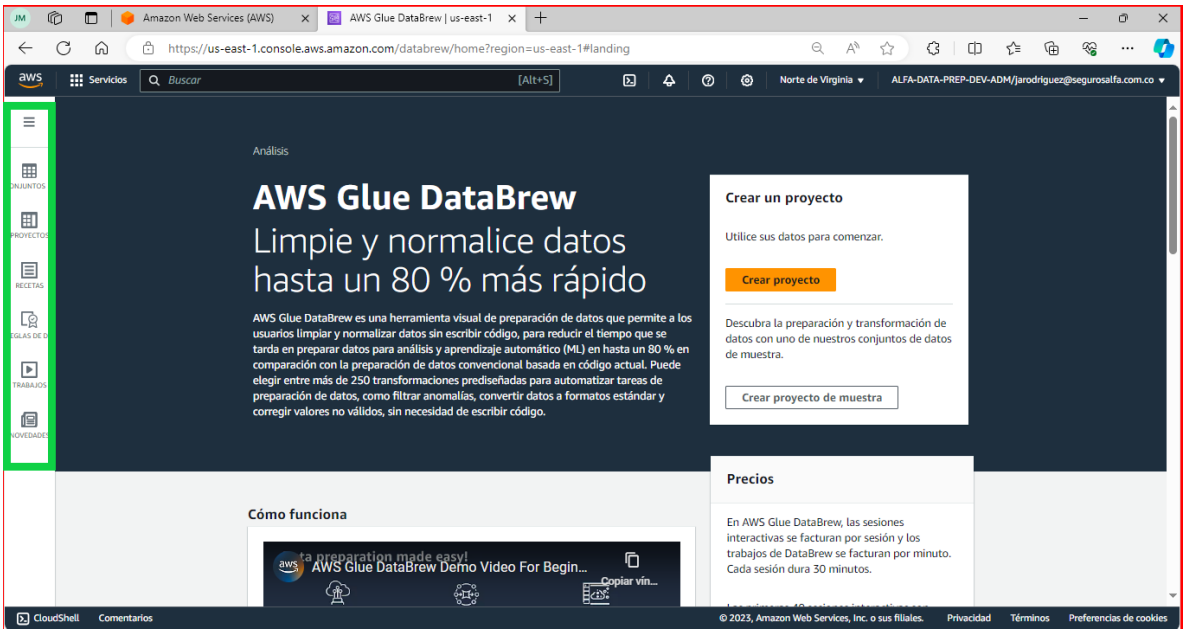
Aparecerá una ventana de confirmación de cargue del archivo. Realizado correctamente.



Luego de cargado el archivo de entrada procedemos a ingresar al servicio de AWS GlueDataBrew. en la opción de servicios buscamos el servicio y damos clic.



A continuación se visualiza la interfaz de la herramienta AWS GlueDataBrew.



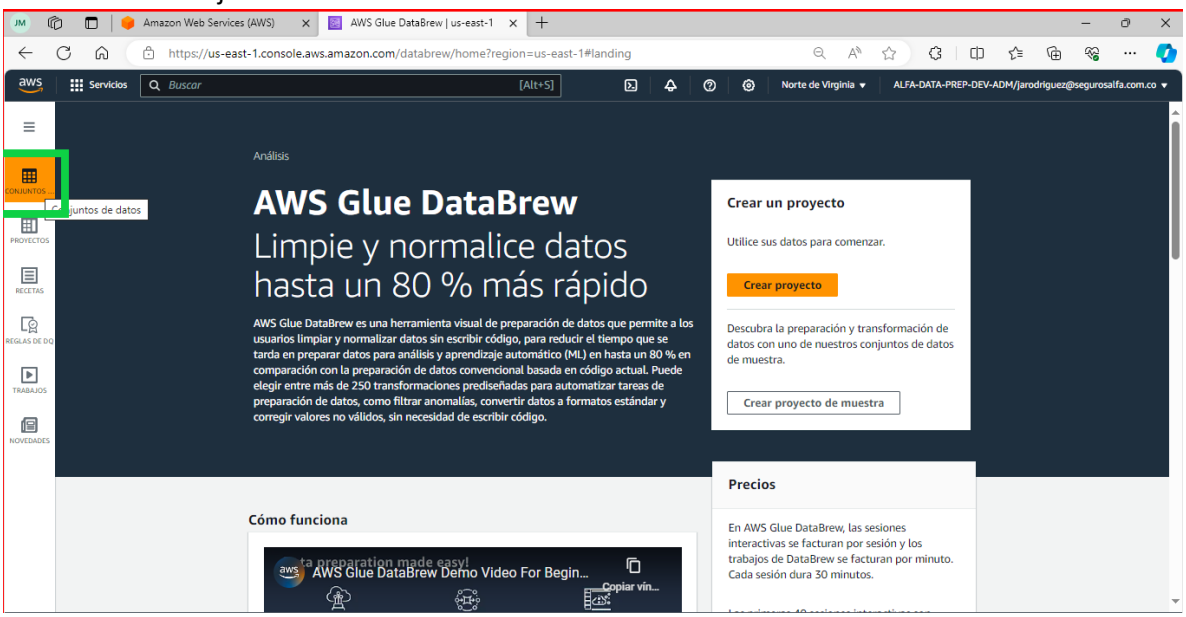
Acá se encontrará varias opciones para iniciar la creación de la receta:

- **Conjuntos**: Donde se crea el dataset apartir del archivo de entrada tomando del servicio S3. Se configura que tipo de archivo se esta procesando, el muestreo y ubicación del dataset.

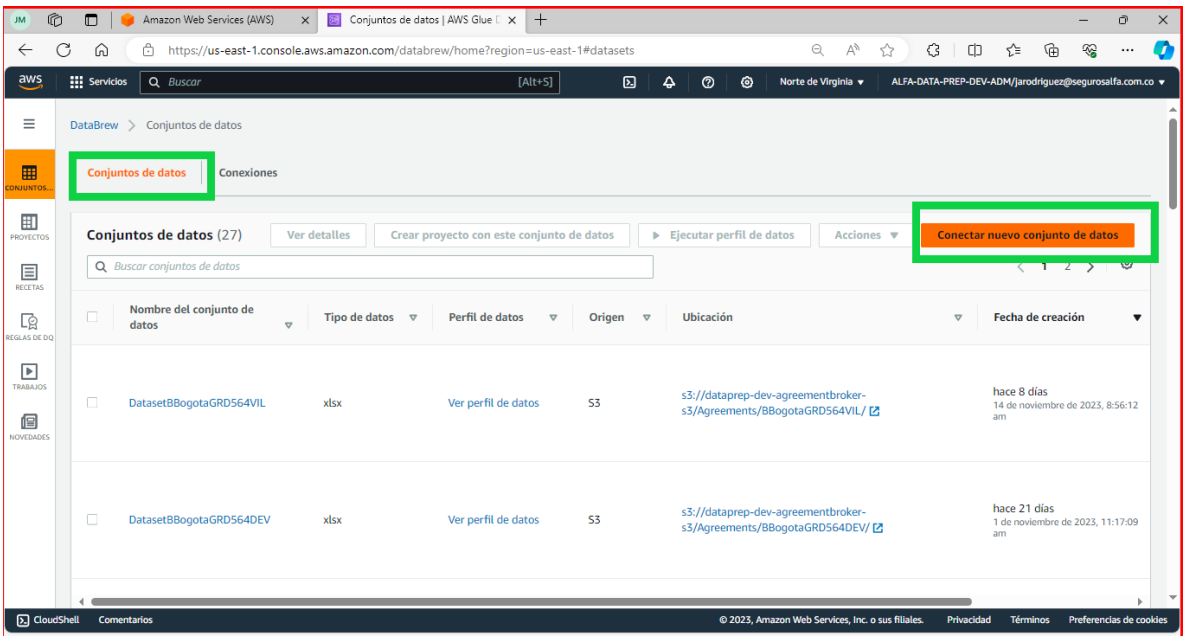
- **Proyectos**: Interfaz que se crea a partir del conjunto de datos para crear el paso a paso de la receta.
- **Recetas**: Lugar donde se publican las recetas construidas en cada unos de proyectos, que es el archivo Json.
- **Reglas de DQ:** Aquí se crean las reglas de calidad de datos que debe cumplir un dataset para luego poder aplicar los pasos de la receta.
- **Trabajos**: Aquí se crean los trabajos de receta los cuales ejecutan los pasos construidos, así como los trabajos de perfil de datos que ejecutan las reglas de calidad.
- **Novedades**: Aquí se encuentran las noticias relacionadas con AWS Glue Databrew, sobre nuevas funcionalidades, ajustes, etc.

Paso para crear un conjunto de datos:

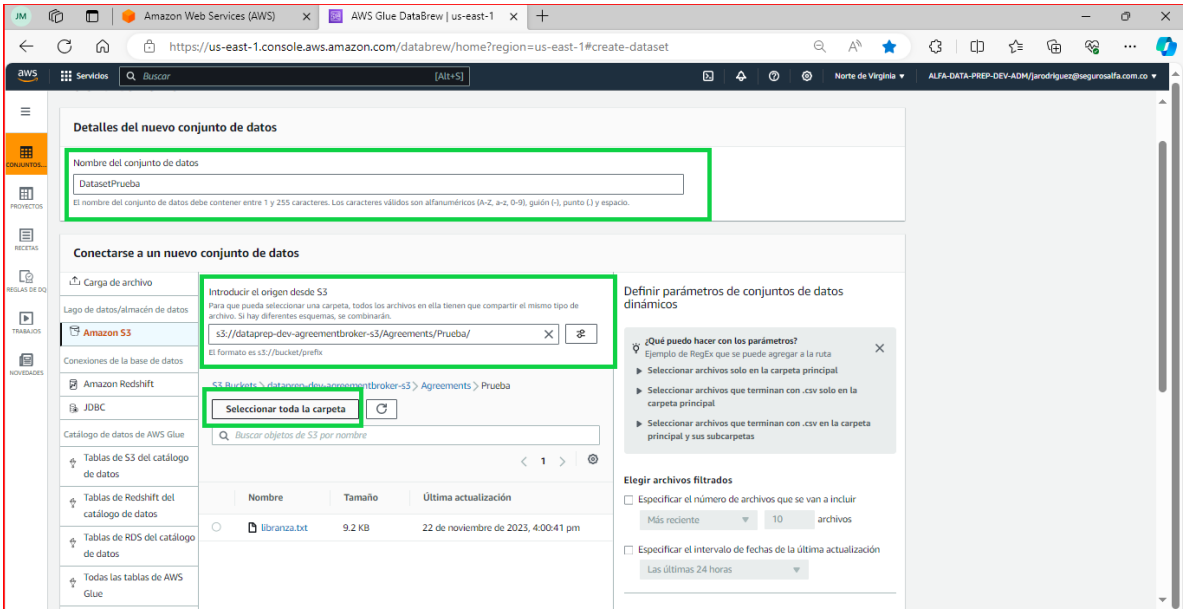
Damos clic en conjunto de datos



Seleccionamos conectar nuevo conjunto de datos.

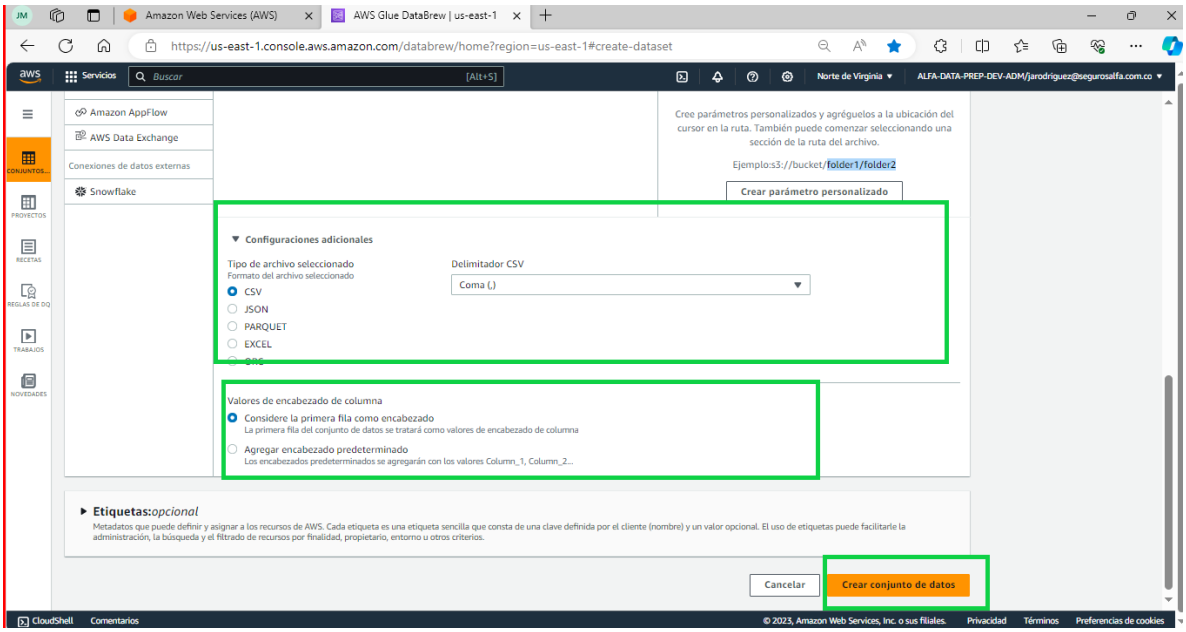


Se debe colocar el nombre estándar **Dataset + nombre ejemplo** DatasetPrueba, luego seleccionar la ruta de la carpeta solo la carpeta donde va estar el archivo de entrada en el S3. Por último, seleccionar la opción **Seleccionar toda la carpeta** como se muestra en la siguiente imagen.

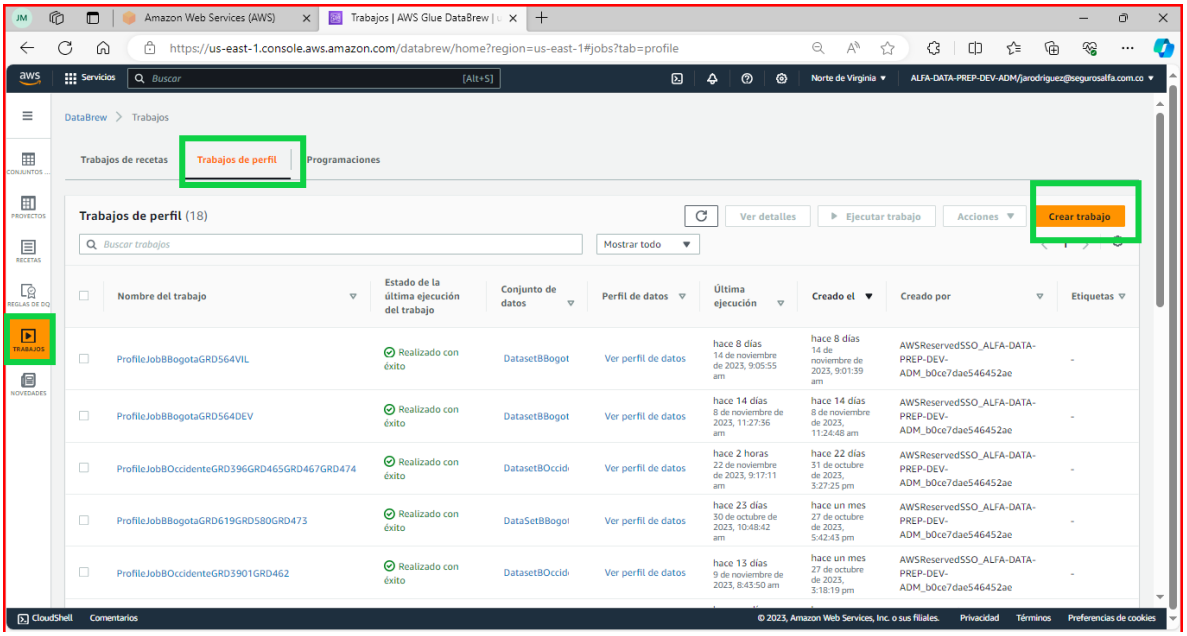


- Seleccionar el tipo de archivo de entrada, en el caso de los csv se requiere definir el tipo de delimitador con el cual esta el archivo. Para los otros archivos solo seleccionar tipo de archivo.
- Luego teniendo en cuenta si el archivo tiene encabezados o no seleccionar de acuerdo Valores de encabezado de columna. Cualquiera de las dos opciones.

Por último, dar clic **Crear conjunto de datos.**

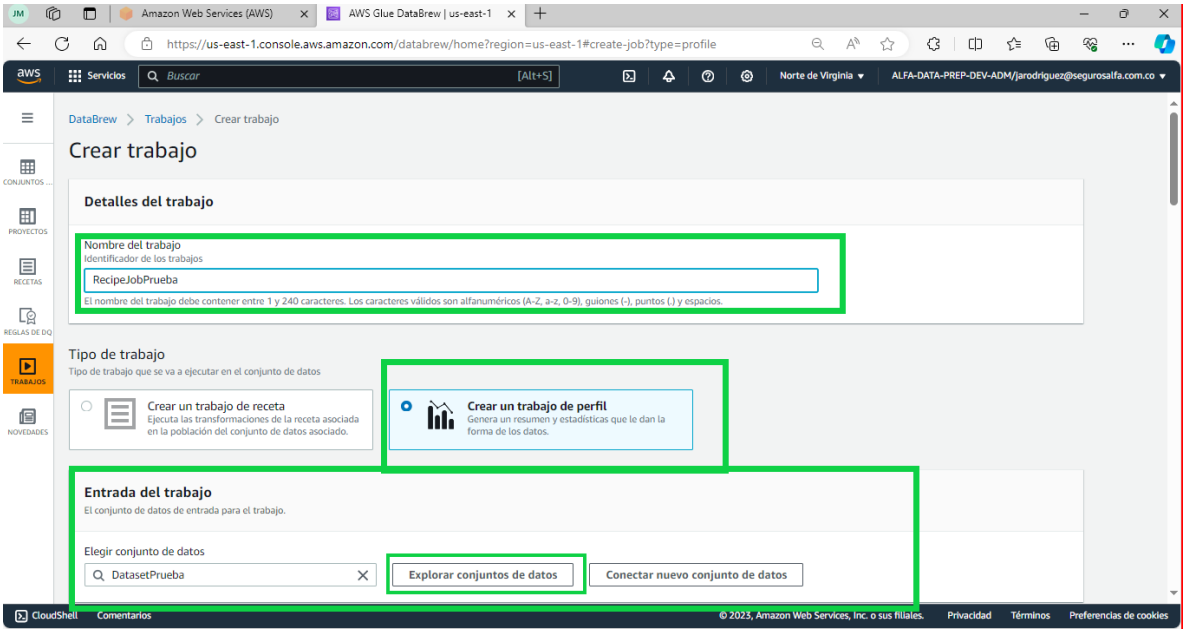


Luego procedemos a crear el trabajo de perfil de datos, en la opción trabajos. Trabajos de perfil y en crear trabajo:

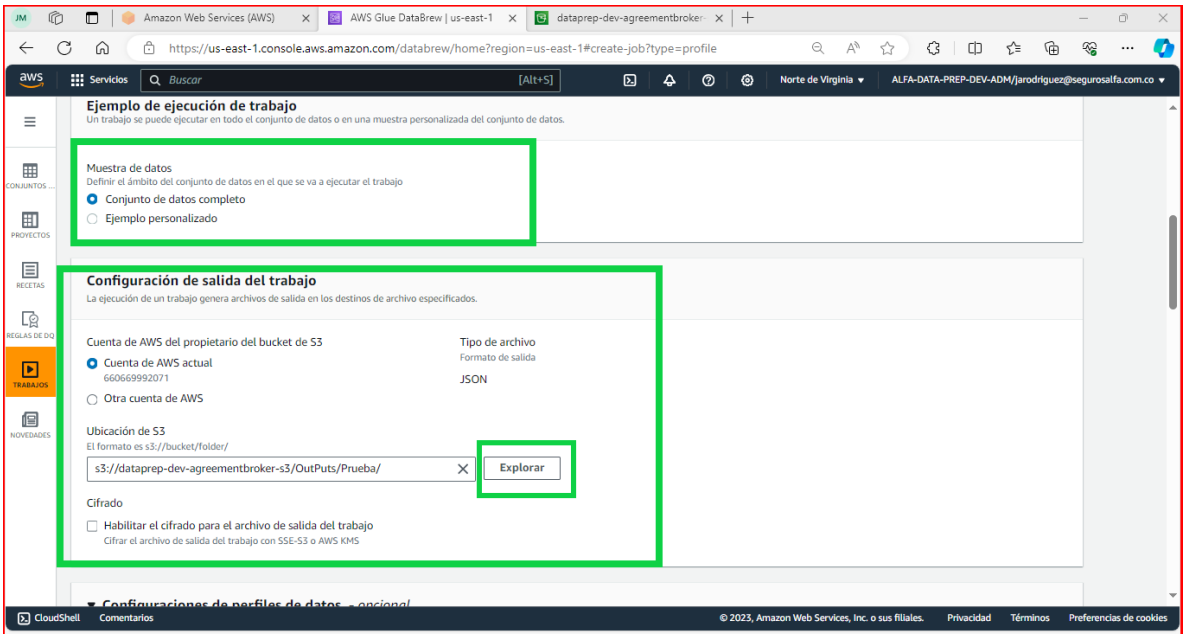


Se procede a crear el trabajo de perfil asociado al Dataset creado anteriormente.

- Crear nombre del trabajo con la siguiente estructura**: ProfileJob+nombre** utilizado para identificar el proceso definido anteriormente ejemplo prueba.
- Elegir el conjunto de datos creado en el paso anterior. Dataset+nombre. En la opción explorar conjunto de datos.

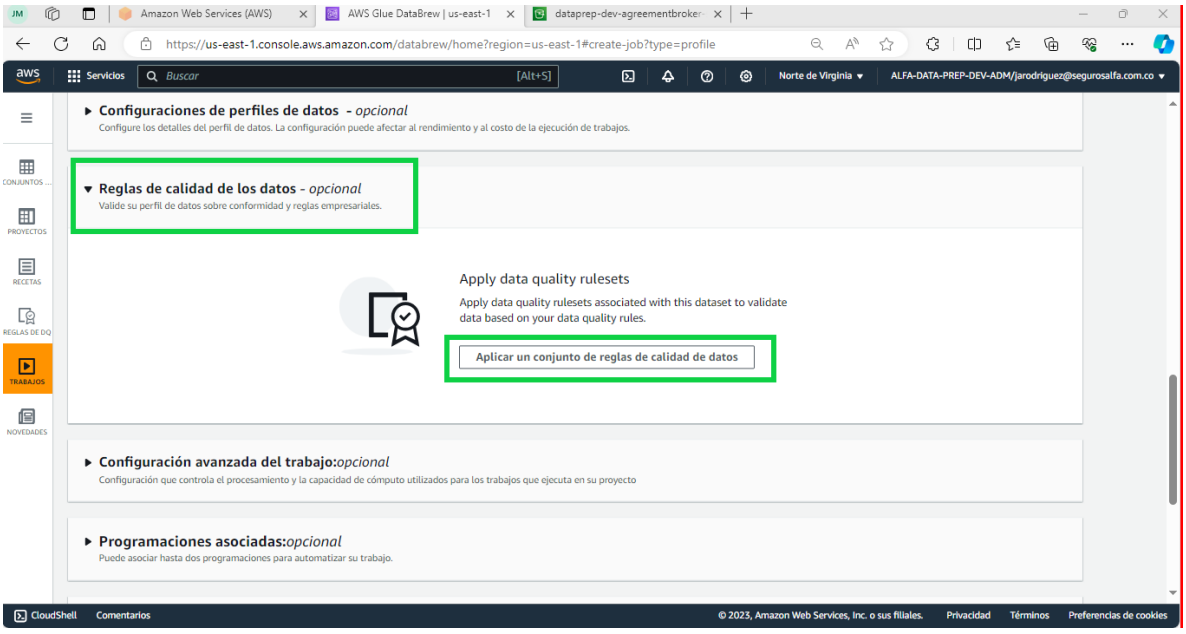


- En la opción Muestra de datos seleccionar: **Conjunto de datos Completo**
- En la configuración de salida del trabajo se debe seleccionar en la opción Explorar, la carpeta OutPuts donde va quedar la salida de nuestro proceso la cual debe estar creada con el mismo nombre ejemplo Prueba.

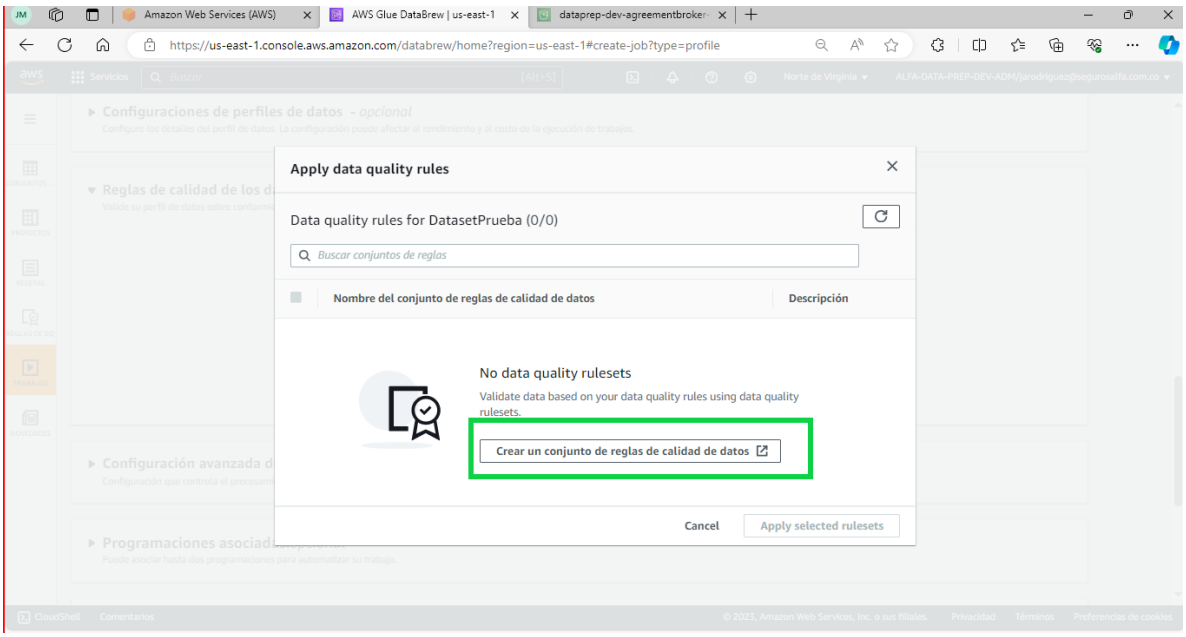


Luego procedemos a crear la regla de calidad de datos en la siguiente opción.

Aplicar un conjunto de reglas de calidad de datos.

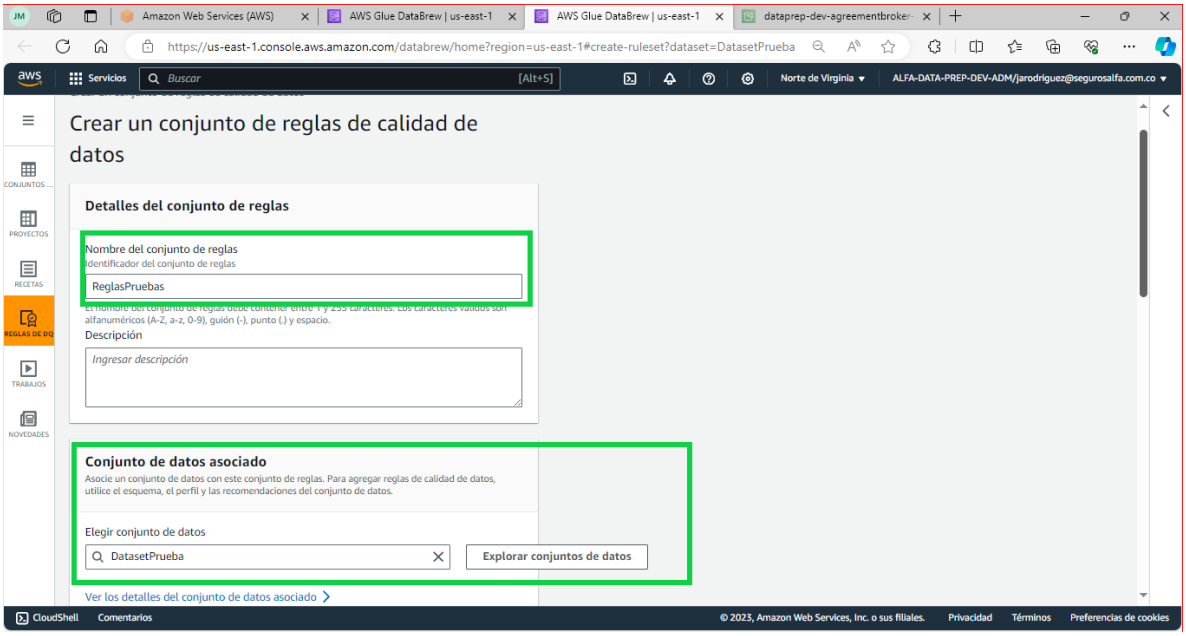


Dar clic en Crear un conjunto de reglas de calidad de datos.



Se abrirá una nueva pestaña donde se configura la regla de calidad de datos.

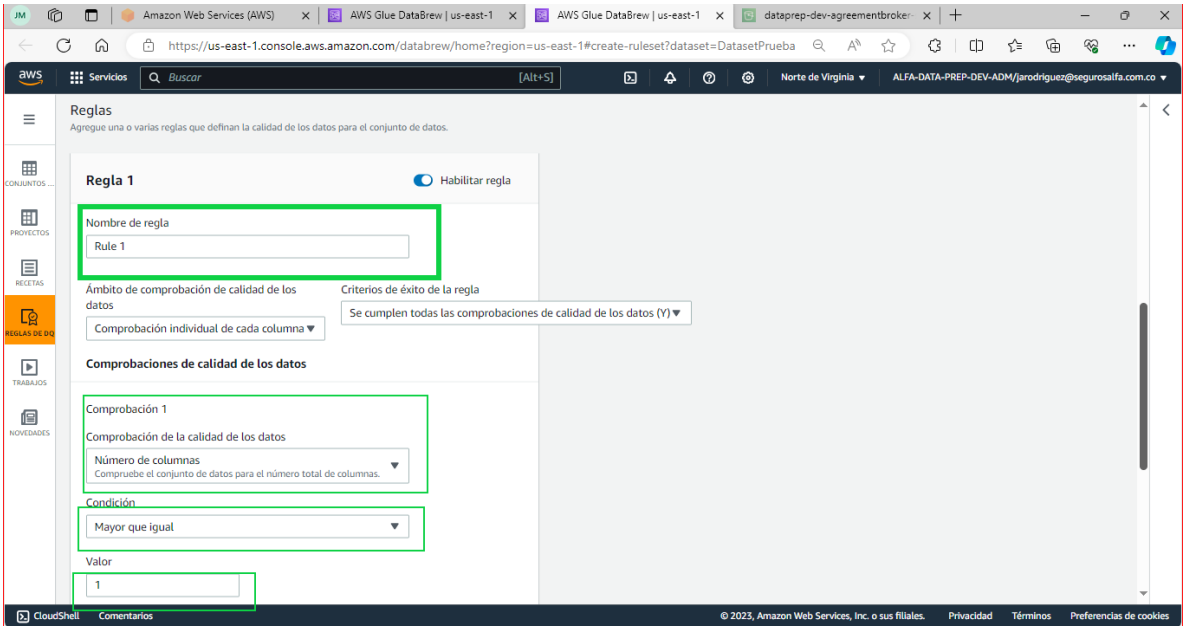
- Se debe colocar el nombre con el prefijo Reglas+nombre de proceso. Ejemplo Prueba.
- En conjunto de datos verificar que sea el mismo DataSet en caso de que no explorar y seleccionar el correcto.



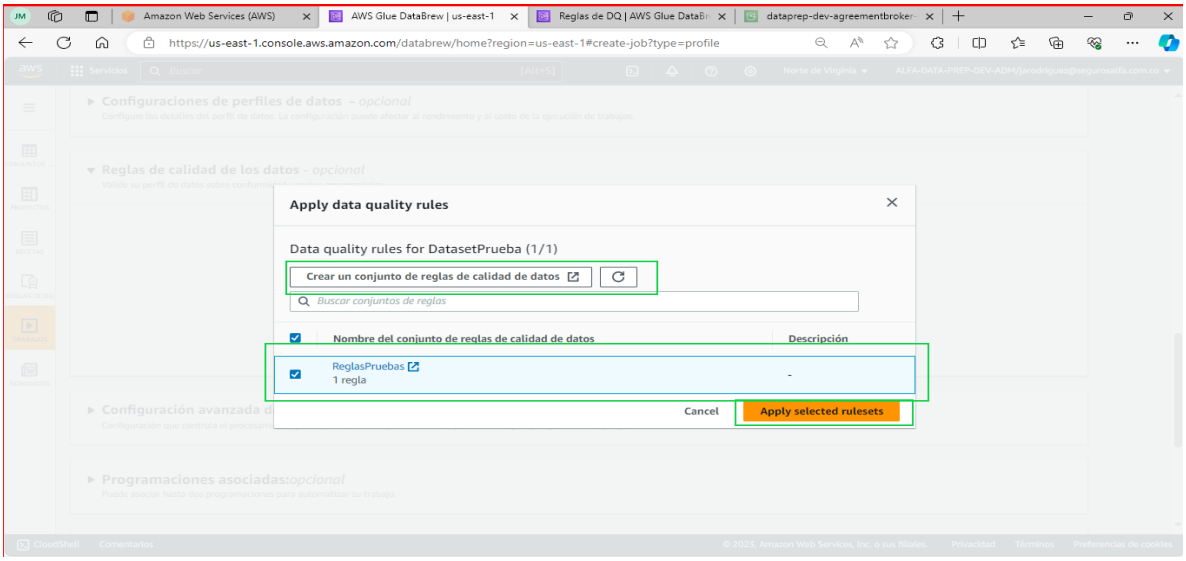
En la parte de reglas se debe configurar de la siguiente manera:

- Nombre de la regla se puede dejar por defecto Rule 1 o Regla 1.
- Dejar por defecto Comprobación individual de cada columna y se cumplen todas las comprobaciones de calidad de los datos.
- En comprobación 1/ Comprobación de la calidad de datos dejar número de columnas.
- Condición mayor que igual
- Valor 1.

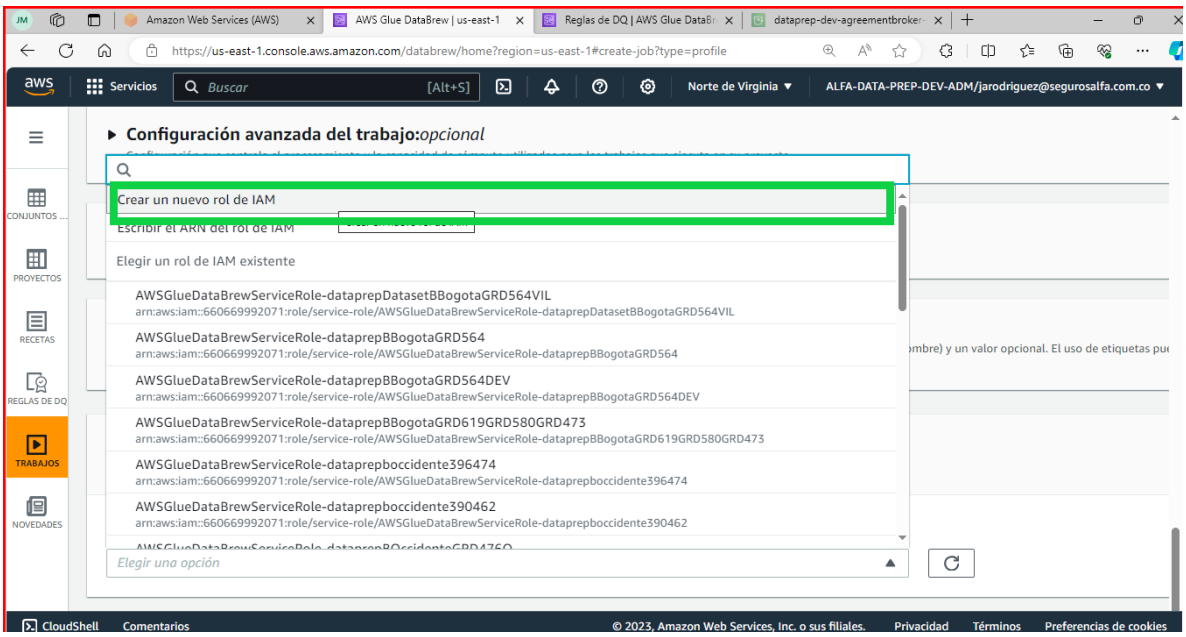
Al finalizar Dar clic en Crear conjunto de reglas.



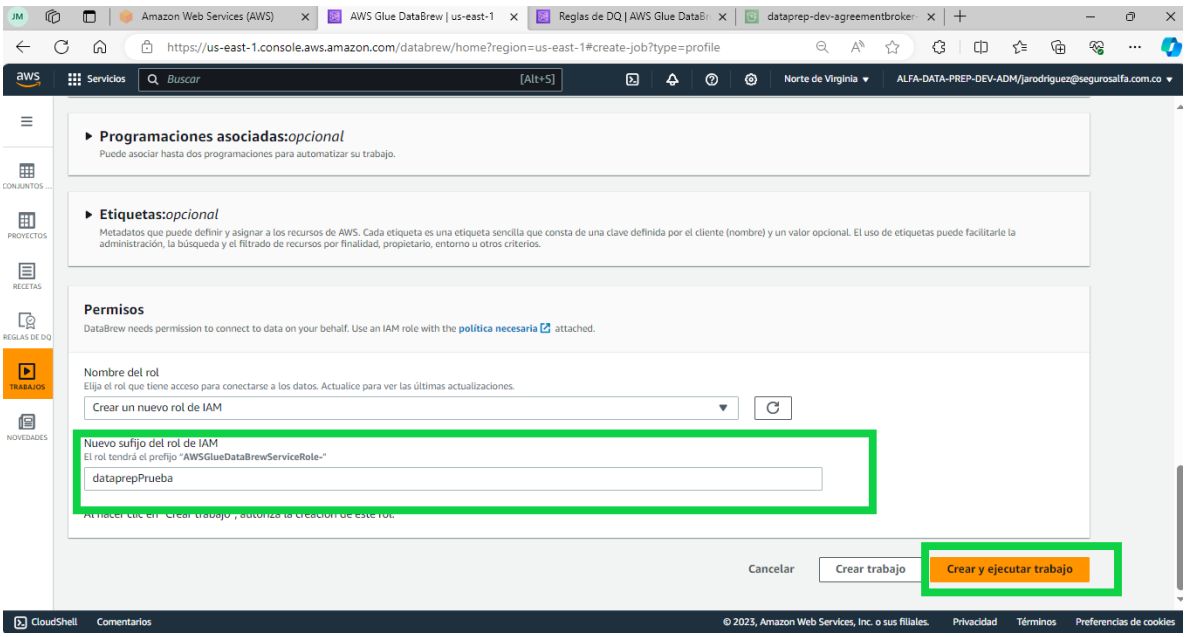
Volvemos a la pestaña del trabajo del perfil y damos actualizar para que nos muestre la regla que se creó. La seleccionamos y damos clic en Apply Selected Rulesets.



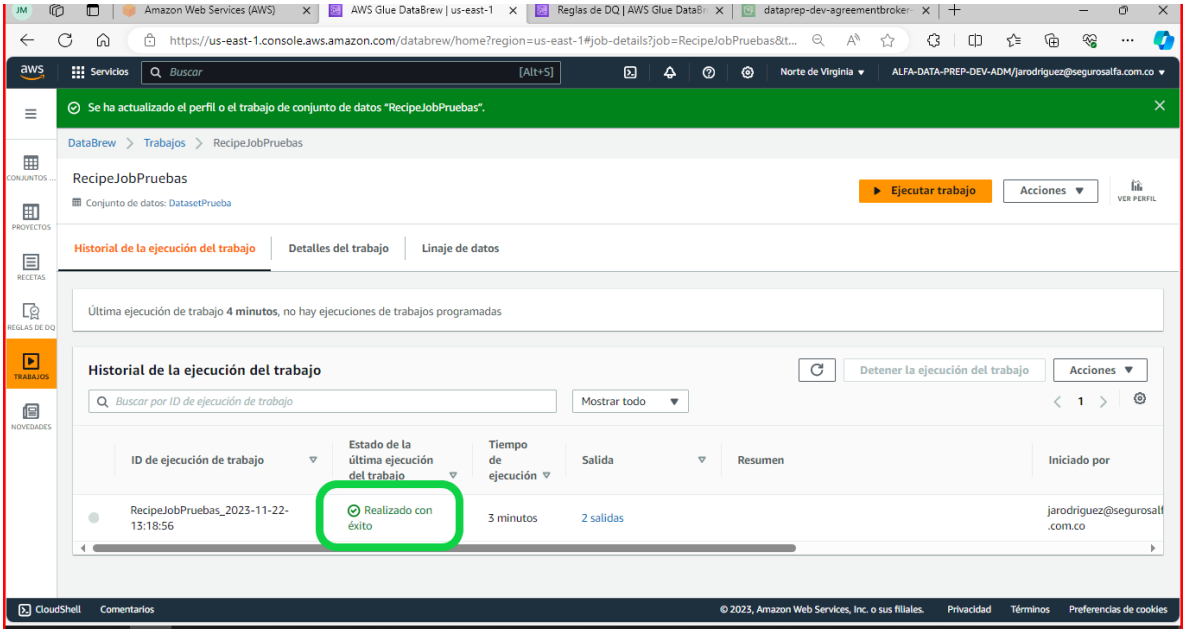
En la parte de permisos seleccionar en lista desplegable, crear un nuevo rol de IAM.



En la parte de nuevo sufijo del rol del IAM se debe colocar el prefijo dataprep + nombre ejemplo dataprepPrueba de acuerdo con el mismo nombre del proceso. Al finalizar dar en crear y ejecutar trabajo.

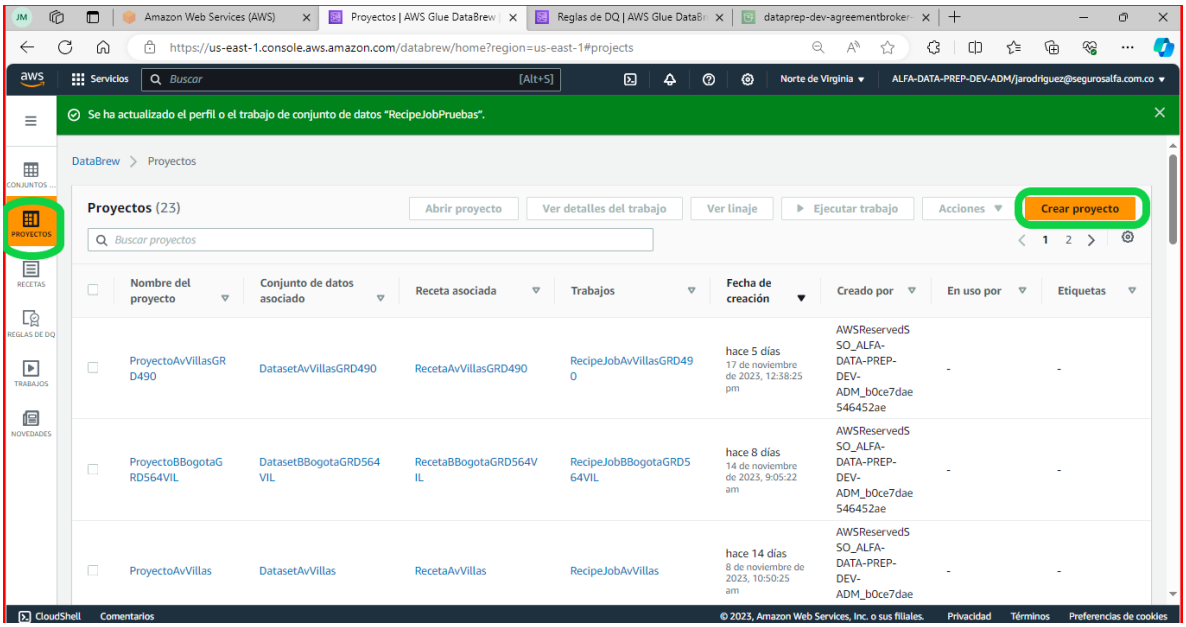


A continuación, se visualiza el historial de ejecución donde se debe visualizar el estado exitoso.
Este trabajo de perfil solamente se ejecuta una sola vez.

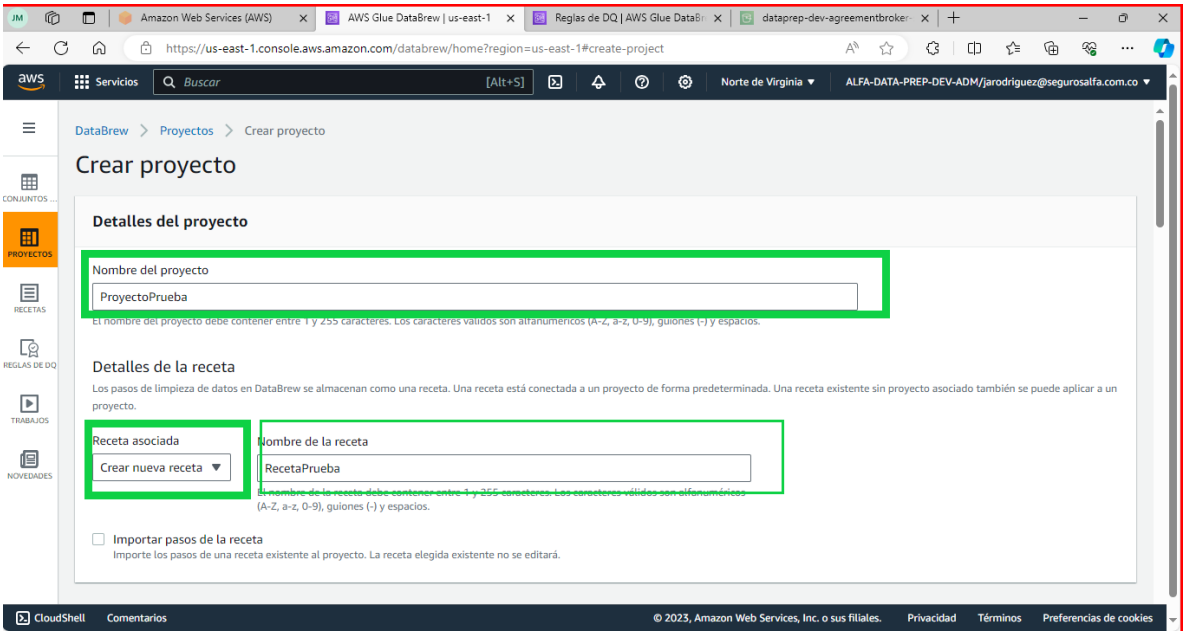


PROYECTOS:

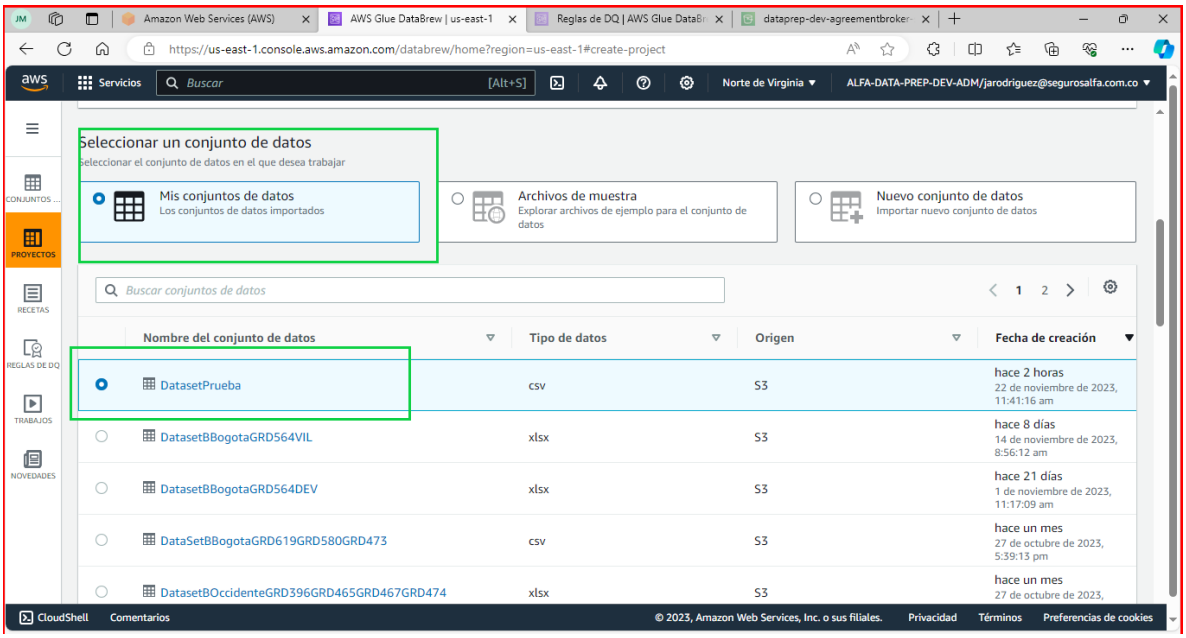
Vamos a la sección de proyectos donde se crear el nuevo proyecto.



Se debe colocar el nombre como Proyecto+nombre ejemplo ProyectoPrueba y en receta asociada se selecciona crear nueva receta donde debe llevar el nombre Receta+nombre ejemplo RecetaPrueba.

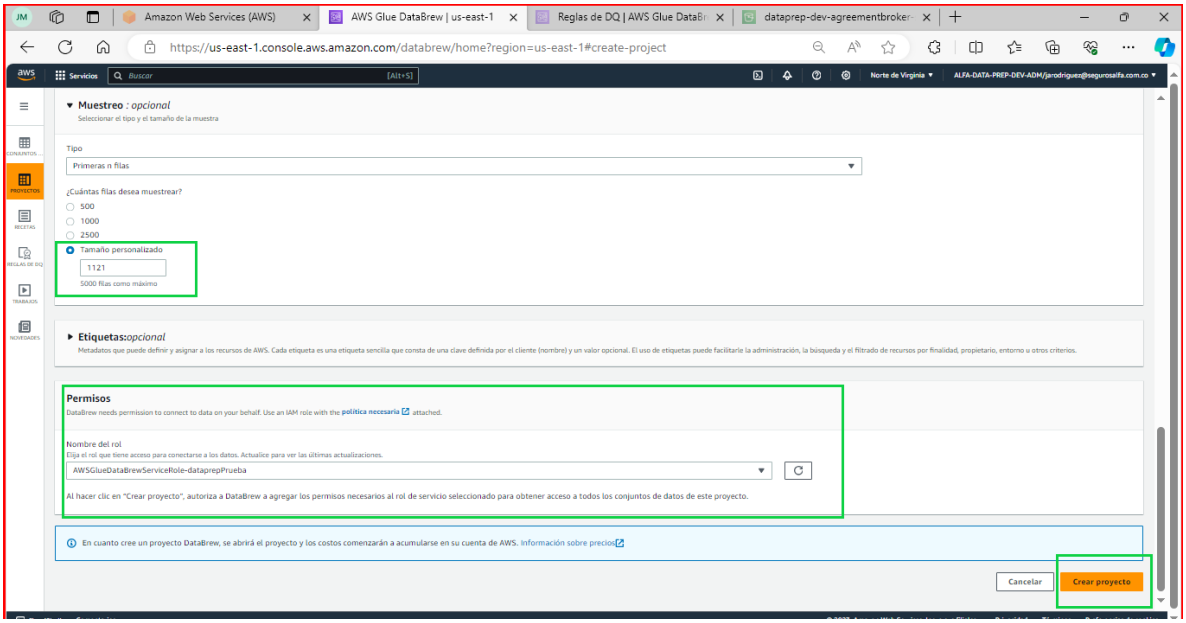


A continuación, seleccionar el conjunto de datos creado anteriormente.

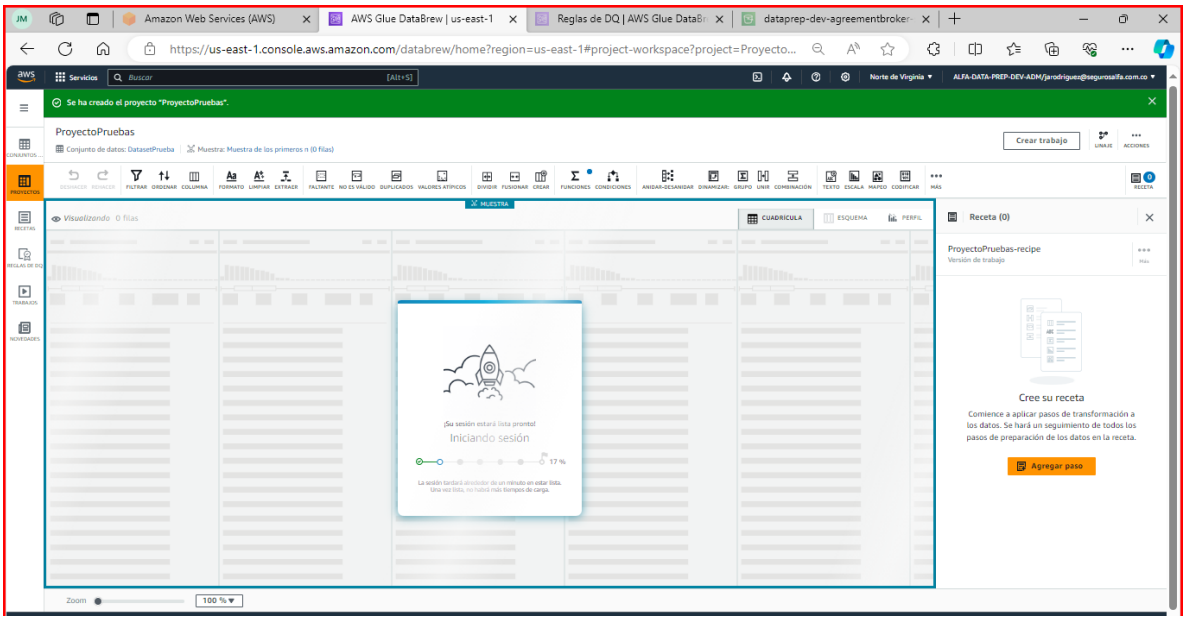


Luego se debe seleccionar en muestreo tamaño personalizado. Recomendado 1121.

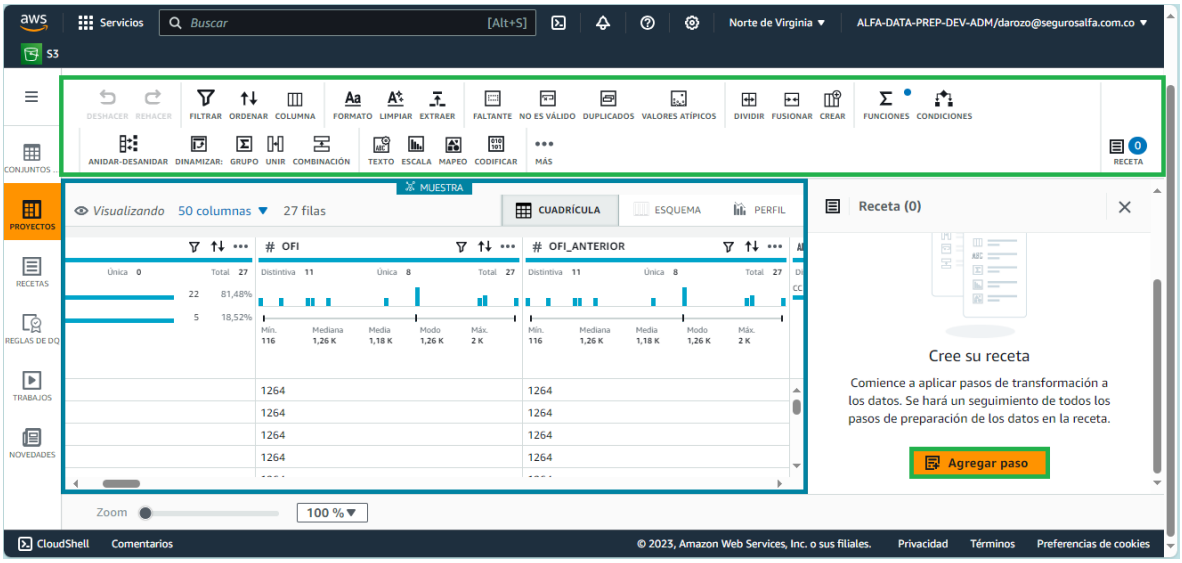
En permisos seleccionar el rol creado para el proceso el cual tiene el mismo nombre que se identifica. Finalizar dando clic en crear proyecto.



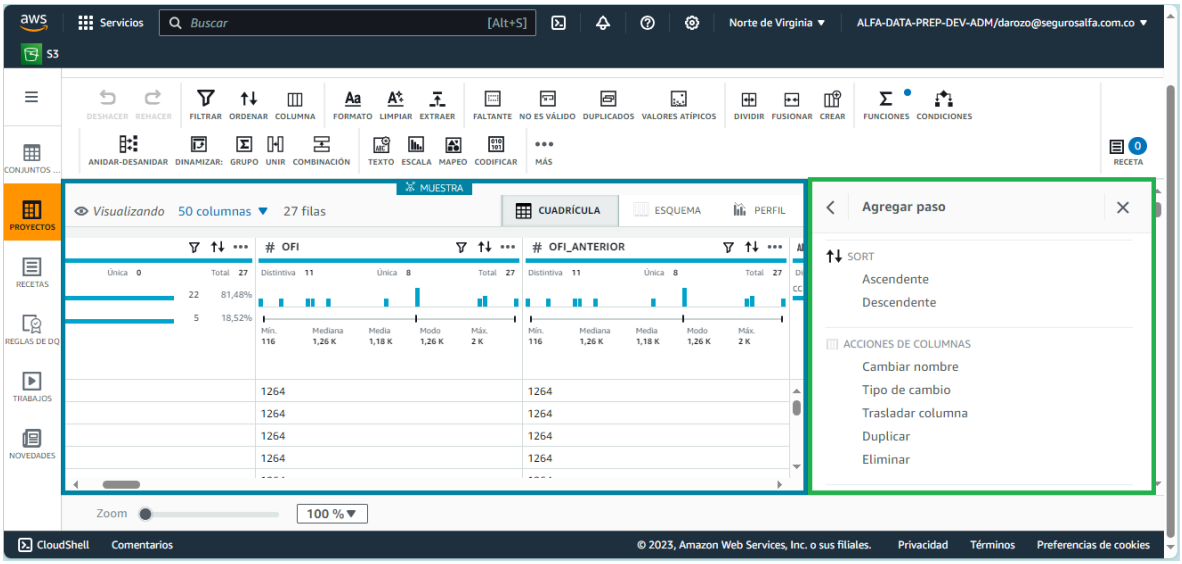
Aparecerá la siguiente pantalla donde se cargará la data del archivo y la preparación para comenzar a construir la receta.



Luego de crear el proyecto se puede iniciar la construcción de los pasos de la receta, para esto se puede dar click en el botón naranja a la derecha de la pantalla con el nombre “Agregar paso”. En la parte superior se encuentran las funciones que se pueden utilizar para la transformación de los datos.

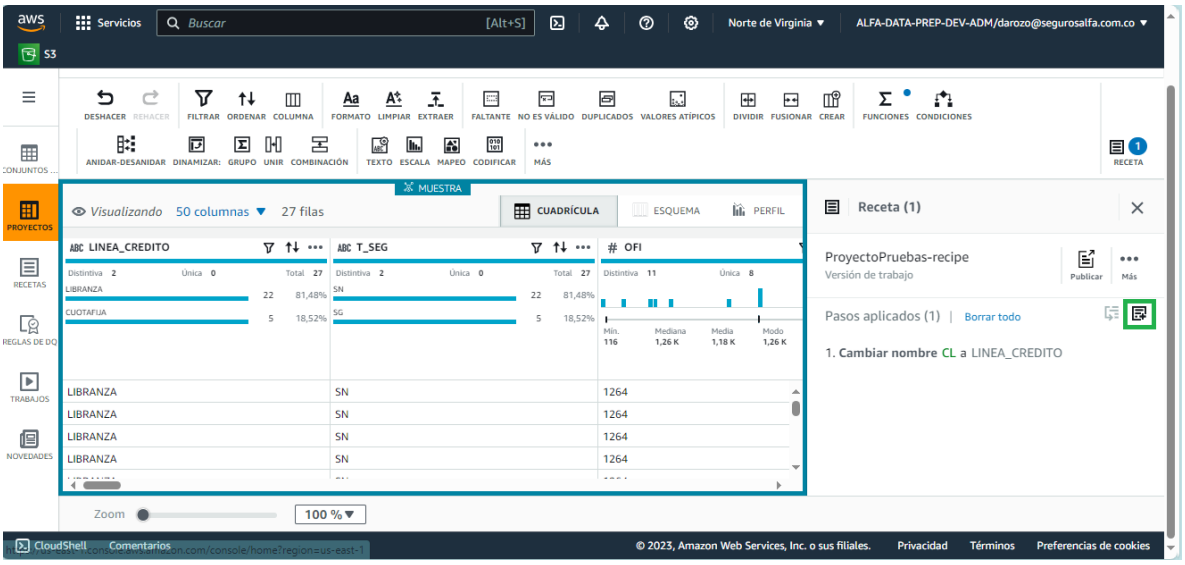


Al dar click en “Agregar paso” se despliega una lista con los diferentes tipos de transformación que se pueden aplicar

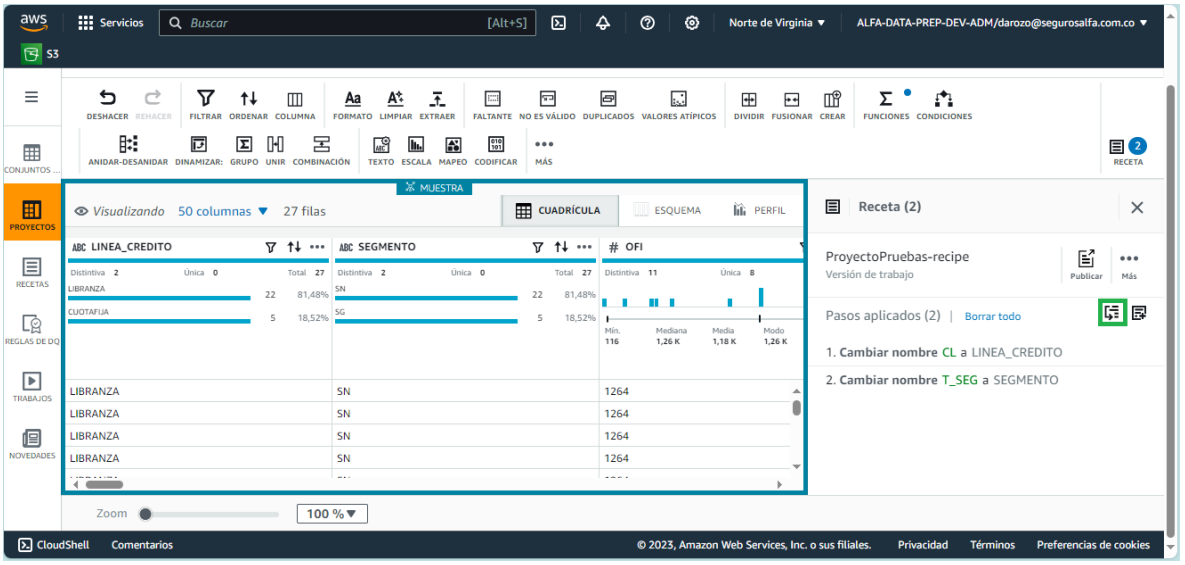


Después de crear el primer paso, este se verá en la sección derecha en donde se puede editar o eliminar, aquí también se encontrarán dos botones: el primero para reordenar los pasos y el segundo para agregar un nuevo paso a la receta

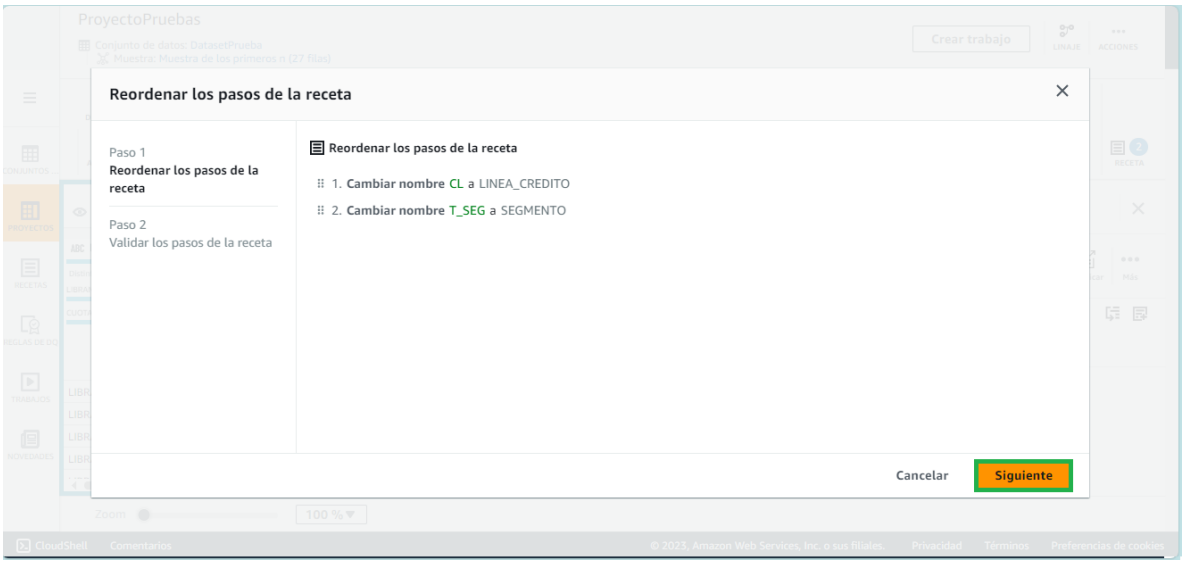
Aquí se puede agregar un nuevo paso dando click en el botón resaltado en verde



Aquí se puede realizar un reordenamiento de pasos en caso de ser necesario:

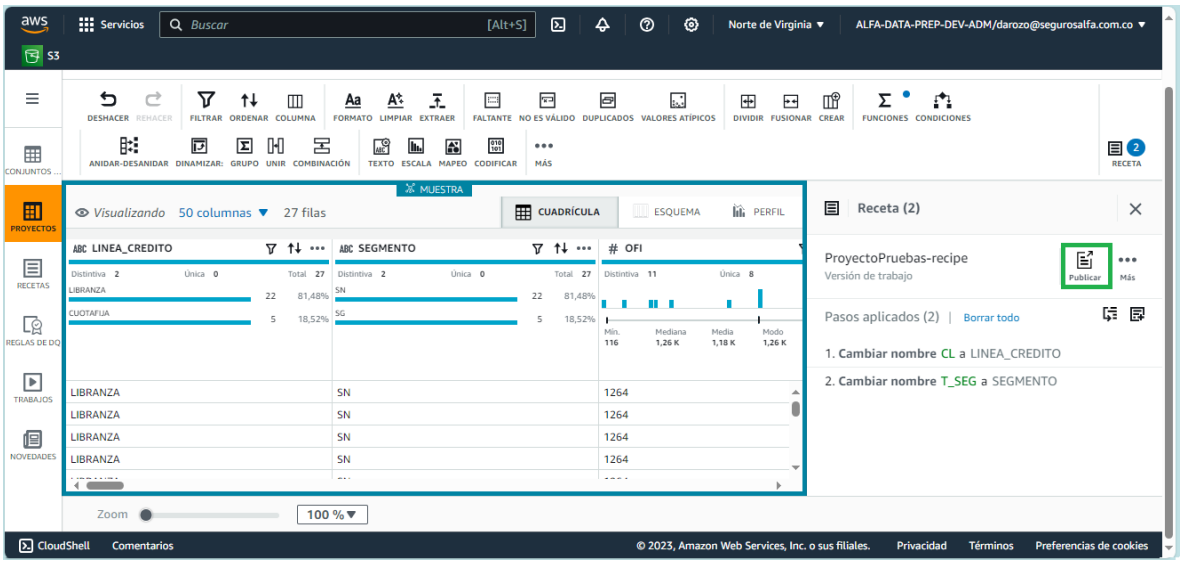


Al dar click en el botón se abre una pantalla en la cual se pueden ordenar los pasos de acuerdo con la necesidad

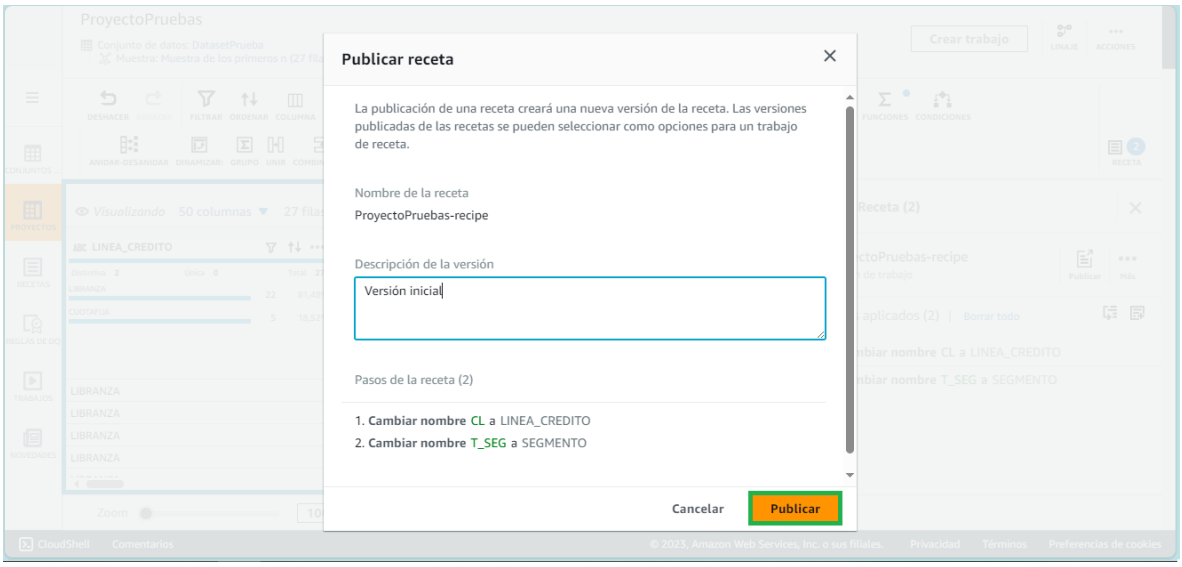


Luego de ordenar los pasos se oprime el botón siguiente y se iniciará una validación de los pasos para confirmar que la modificación no afecta la construcción de la receta. Sí la validación se completa correctamente quedarán los pasos en el orden establecido, de lo contrario mostrará una alerta y será necesario cancelar el proceso y revisar si algún paso más adelante tiene alguna dependencia del paso que se está reordenando.

Luego de terminar la construcción de la receta esta se debe publicar dando click en el botón “Publicar”

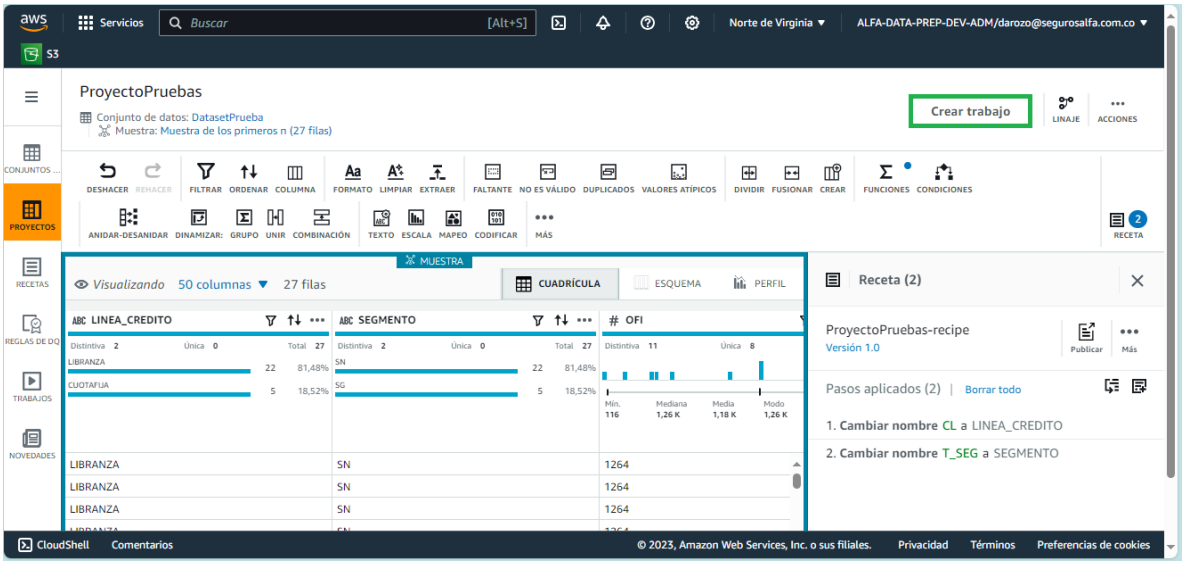


Al dar click en “Publicar” se despliega una ventana en la cuál se adiciona un comentario sobre la receta que se va a publicar y se da click en el botón “Publicar” nuevamente

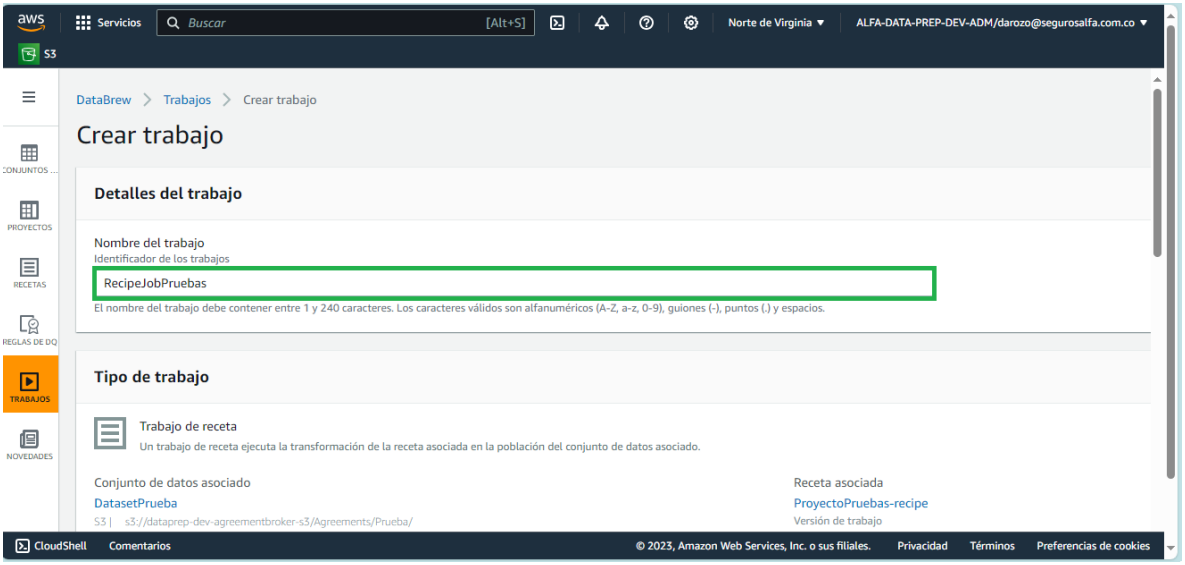


En caso de que se requiera realizar un ajuste o agregar nuevos pasos se debe publicar nuevamente la receta indicando en el comentario la modificación que se hizo

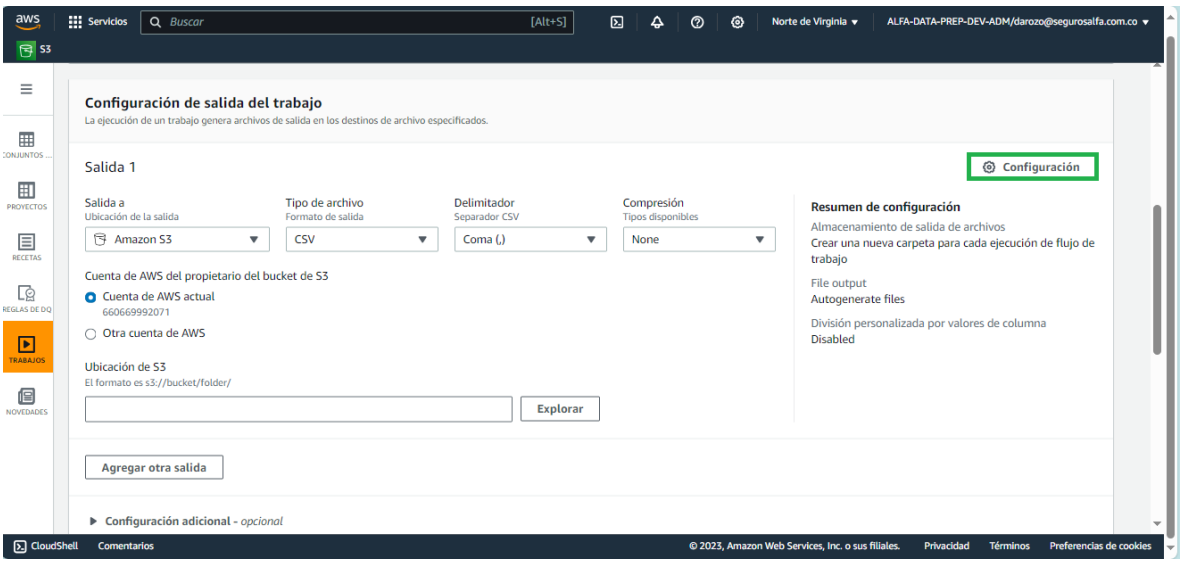
Luego de publicar la receta se debe crear el job que ejecutará dichos pasos, se debe dar click en el botón “Crear trabajo”, luego de esto se abre una pestaña en donde se debe configurar el job



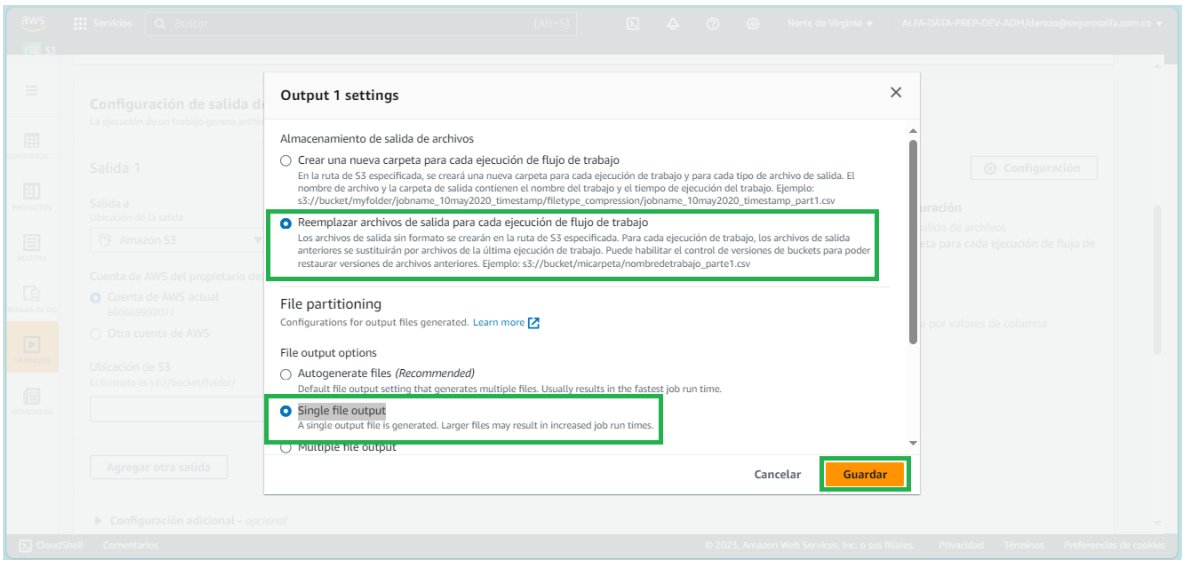
El primer paso es nombrar el proyecto, se debe colocar RecipeJob seguido del nombre de proyecto RecipeJob + Nombre proyecto. Ejemplo: RecipeJobPrueba



Luego se debe configurar la salida, para esto inicialmente se debe dar click en el botón “Configuración”



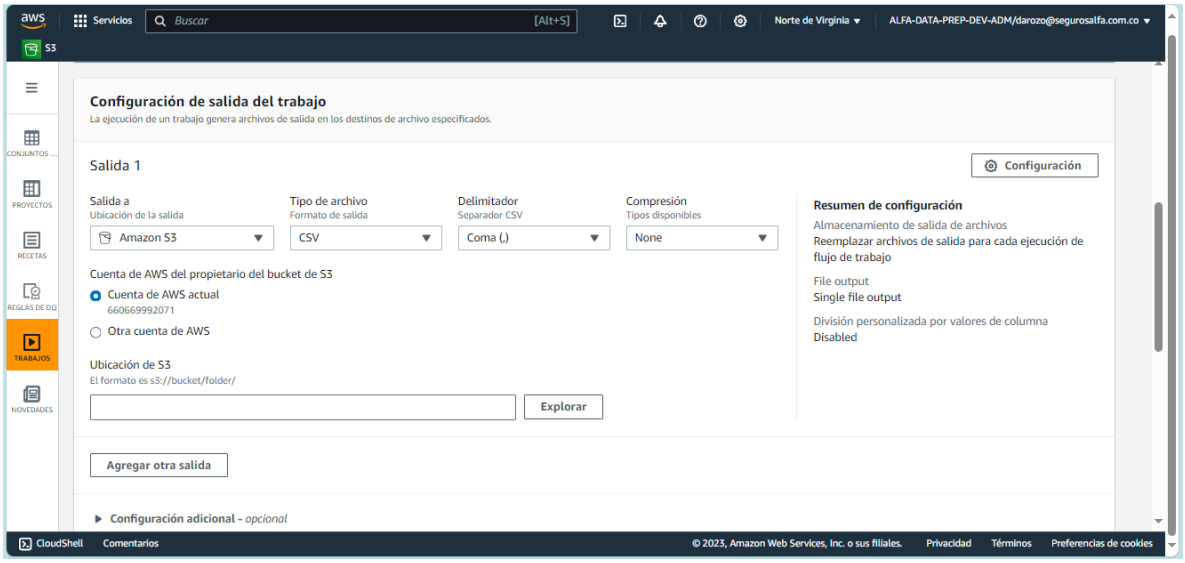
Se desplegará una ventana en las cuales se deben marcar las opciones “Reemplazar archivos de salida para cada ejecución de flujo de trabajo” y “Single file output”, finalmente se oprime el botón “Guardar”



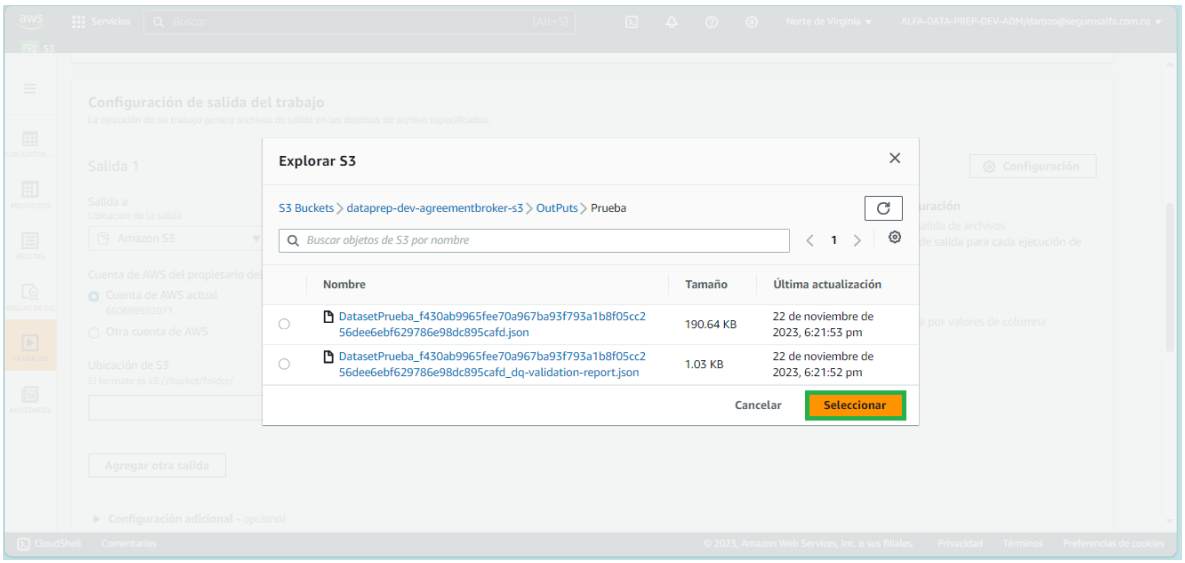
Enseguida se debe configurar la ruta en donde va a quedar almacenado el archivo de salida, por defecto está establecida la siguiente configuración:

- Salida a: Amazon S3
- Tipo de archivo: CSV
- Delimitador: Coma (,)
- Compresión: None
- Cuenta de AWS del propietario del bucket de S3: Cuenta de AWS actual

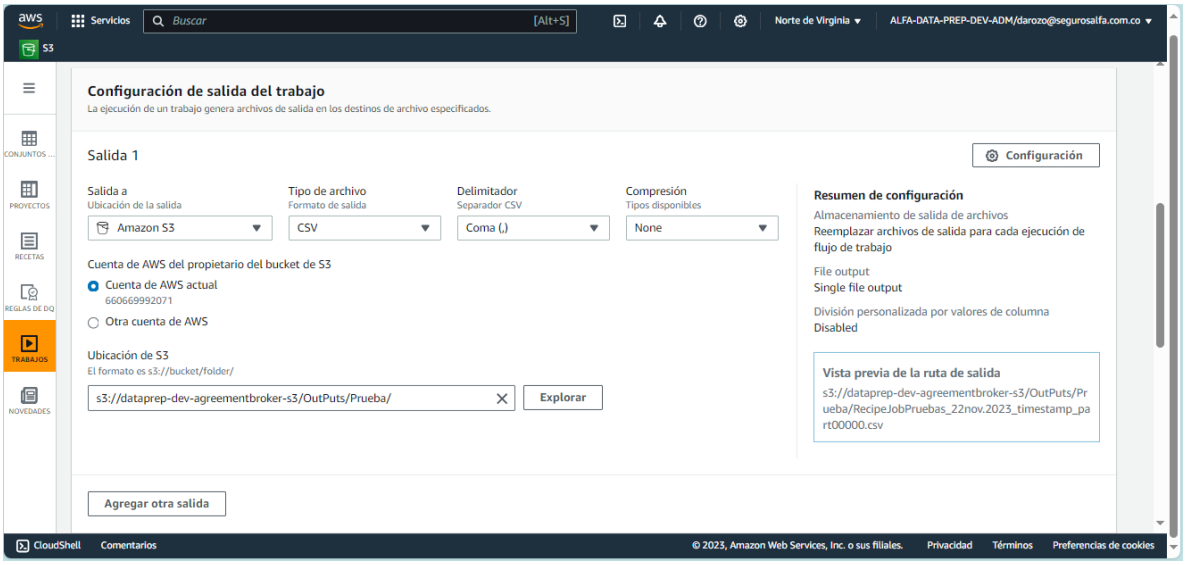
Esta configuración no se debe modificar así que en este paso solo se debe establecer la tuta de salida



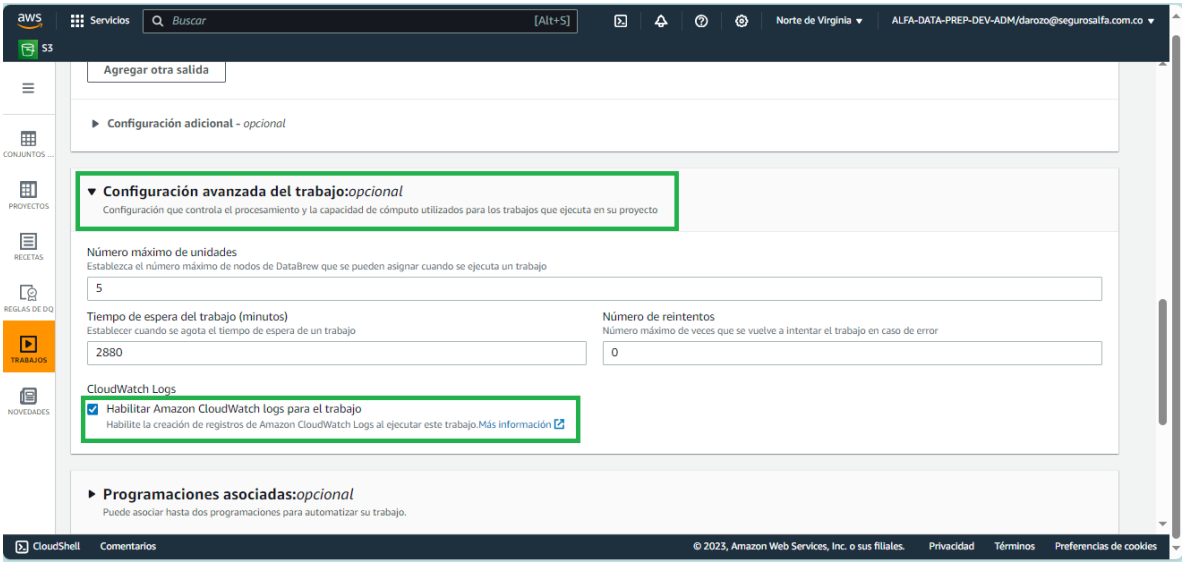
Al dar click en el botón “Explorar” se despliega una ventana en la cuál se debe navegar para establecer la ruta, esta ruta es: dataprep-dev-agreementbroker-s3/Outputs/Carpeta-proyecto. Se selecciona la carpeta del proyecto y se da click en “Seleccionar”



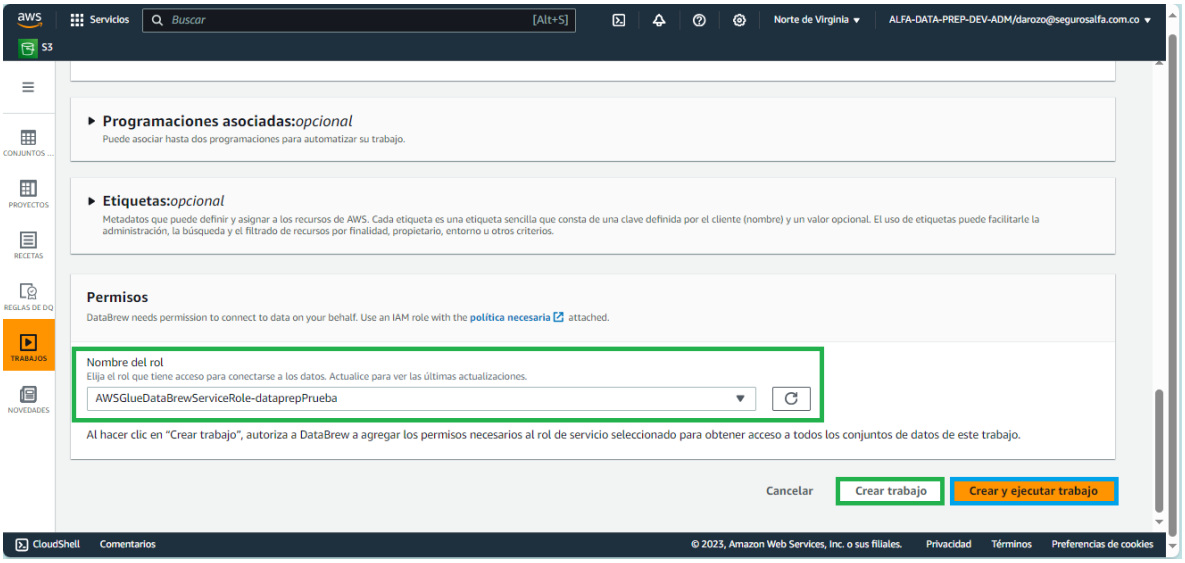
La configuración final de la salida se verá de la siguiente manera:



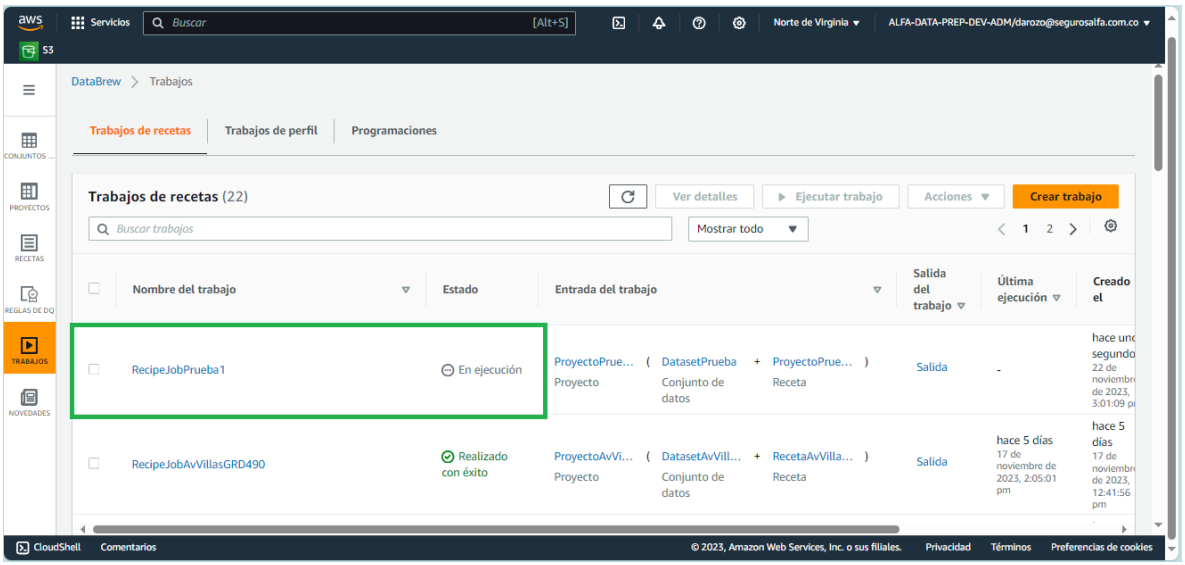
Para el siguiente paso se debe desplegar la pestaña “Configuración avanzada del trabajo” y marcar el check “Habilitar Amazon CloudWatch logs para el trabajo”, el cual es necesario para ver los logs en caso de que falle la ejecución.



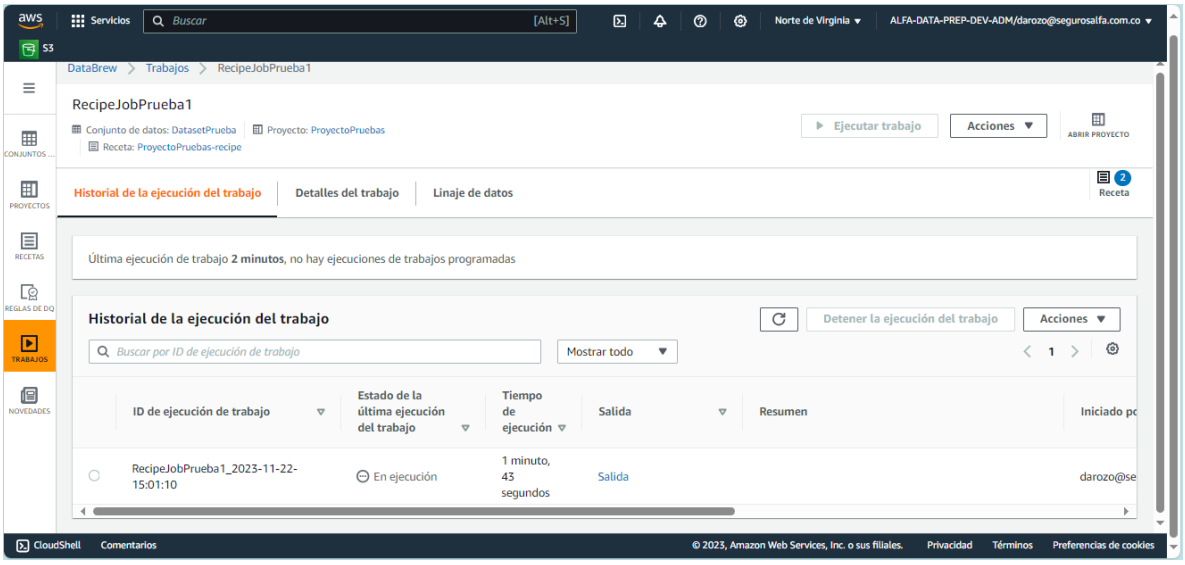
Finalmente se debe seleccionar el rol definido al momento de crear el proyecto y dar click en el botón “Crear trabajo” o “Crear y ejecutar trabajo”



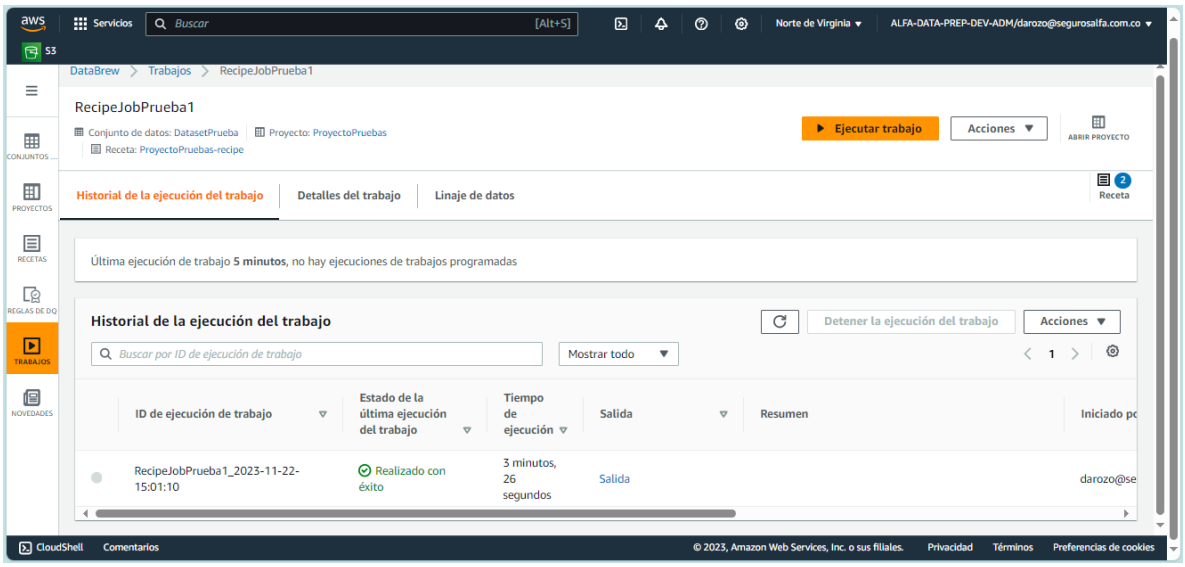
En la sección trabajos se puede observar el estado de ejecución del trabajo



Al dar click sobre el nombre del job se despliega un histórico de las ejecuciones



Si el job termina de manera exitosa se mostrará “Realizado con éxito” en verde, de lo contrario se mostrará “fallo” en rojo



En caso de presentar fallos se debe revisar el log y hacer el ajuste correspondiente en la receta, publicar nuevamente y ejecutar le job.